BÁO CÁO HỌC PHẦN

NHẬP MÔN DỮ LIỆU LỚN

PHÂN TÍCH PHẢN ỨNG CỦA KHÁN GIẢ VIỆT NAM ĐỐI VỚI NHẠC AI TRÊN YOUTUBE

Giảng viên hướng dẫn: Nguyễn Văn Chức

Nhóm thực hiện

Nguyễn Thiện Bảo
Trần Nguyễn Hữu Minh
Nguyễn Anh Tú
Nguyễn Đắc Anh Khoa

Tháng 10 năm 2026

BẢNG PHÂN CÔNG CÔNG VIỆC

STT	Họ và tên	MSSV	Công việc phụ trách	Đóng góp
1	Nguyễn Thiện Bảo (nhóm trưởng)	Chưa cung cấp	Điều phối, tổng hợp và rà soát báo cáo; dashboard, phát hiện chính; Chương 1, mục 4.4 và 5.5.	25%
2	Trần Nguyễn Hữu Minh	Chưa cung cấp	GSDMM, diễn giải cụm, khía cạnh và cảm xúc; mục 2.3–2.4, 3.4, 4.3, 5.2–5.3.	25%
3	Nguyễn Anh Tú	Chưa cung cấp	Tiền xử lý Spark, lưu trữ Parquet, PostgreSQL và xuất dữ liệu; mục 3.3, 3.5, 5.1, Phụ lục B.	25%
4	Nguyễn Đắc Anh Khoa	Chưa cung cấp	Thu thập API, Docker, Airflow và kiểm tra quy trình; mục 3.1–3.2, 4.1–4.2 và 5.4.	25%

Các thành viên cùng thực hiện mục 2.1, 2.2, 2.5, Chương 6, Phụ lục A; rà soát tài liệu tham khảo, chuẩn bị nội dung và thuyết trình. Mã số sinh viên chưa được cung cấp trong tài liệu đầu vào.

MỤC LỤC

LỜI CẢM ƠN **5**
LỜI MỞ ĐẦU **6**
CHƯƠNG 1. TỔNG QUAN ĐỀ TÀI **7**
1.1. Giới thiệu đề tài 7
1.1.1. Bối cảnh và lý do chọn đề tài 7
1.1.2. Mục tiêu của đề tài 8
1.2. Tổng quan về nguồn dữ liệu 8
1.3. Đối tượng và phạm vi nghiên cứu 9
1.4. Ý nghĩa thực tiễn của đề tài 11
CHƯƠNG 2. CƠ SỞ LÝ THUYẾT VÀ NGHIÊN CỨU LIÊN QUAN **12**
2.1. Tổng quan về nhạc AI và dữ liệu YouTube 12
2.2. Phân tích cảm xúc và phân tích cảm xúc theo khía cạnh 13
2.3. Mô hình chủ đề cho văn bản ngắn và thuật toán GSDMM 14
2.4. Mô hình ViSoBERT và ứng dụng phân tích cảm xúc tiếng Việt 16
2.5. Các nghiên cứu liên quan và khoảng trống nghiên cứu 17
CHƯƠNG 3. KIẾN TRÚC HỆ THỐNG VÀ PHƯƠNG PHÁP ĐỀ XUẤT **19**
3.1. Kiến trúc tổng quan hệ thống 19
3.2. Phương pháp thu thập dữ liệu tự động 20
3.3. Quy trình tiền xử lý dữ liệu 21
3.4. Phương pháp phân cụm, gán khía cạnh chính và dự đoán cảm xúc 22
3.4.1. Phân cụm bình luận bằng GSDMM 23
3.4.2. Diễn giải cụm và gán một khía cạnh chính cho mỗi bình luận 23
3.4.3. Dự đoán cảm xúc chung bằng mô hình được huấn luyện trước 24
3.4.4. Kết hợp kết quả khía cạnh và cảm xúc để phân tích 24
3.5. Thiết kế hệ thống lưu trữ và cơ sở dữ liệu 25
CHƯƠNG 4. THIẾT KẾ VÀ TRIỂN KHAI HỆ THỐNG **27**
4.1. Môi trường và công nghệ sử dụng 27
4.2. Triển khai module thu thập dữ liệu 28
4.2.1. Thu thập thông tin video 28
4.2.2. Thu thập snapshot tương tác 29
4.2.3. Thu thập bình luận 29
4.2.4. Điều phối và lưu trữ 29
4.3. Triển khai GSDMM, gán khía cạnh và dự đoán cảm xúc 30
4.3.1. Chuẩn bị dữ liệu đầu vào 30
4.3.2. Huấn luyện và lưu phiên bản GSDMM 31
4.3.3. Diễn giải cụm và thiết lập nhãn khía cạnh 31
4.3.4. Gán cụm trong các lần chạy định kỳ 31
4.3.5. Dự đoán cảm xúc 32
4.3.6. Tích hợp vào Airflow 32
4.4. Xây dựng dashboard trực quan hóa 33
CHƯƠNG 5. THỰC NGHIỆM VÀ ĐÁNH GIÁ **35**
5.1. Thống kê và mô tả dữ liệu thu thập 35

5.2. Kết quả phân cụm GSDMM và gán nhãn khía cạnh....36
5.3. Kết quả phân tích cảm xúc theo các nhóm khía cạnh....38
5.4. Kiểm tra tính nhất quán dữ liệu và hoạt động của quy trình....41
5.5. Phân tích kết quả và các phát hiện chính....42
CHƯƠNG 6. KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN....43
6.1. Kết luận....43
6.2. Hạn chế của đề tài....43
6.3. Hướng phát triển....44
TÀI LIỆU THAM KHẢO....46
PHỤ LỤC A. BỘ NHÃN KHÍA CẠNH VÀ CẢM XÚC....48
A.1. Bộ nhãn khía cạnh....48
A.2. Bộ nhãn cảm xúc....48
A.3. Nguyên tắc biểu diễn....49
A.4. Quản lý bảng tên cụm....49
PHỤ LỤC B. LƯỢC ĐỒ DỮ LIỆU VÀ CƠ SỞ DỮ LIỆU....50
B.1. Phân biệt lưu trữ Parquet và PostgreSQL....50
B.2. Bảng fact_comment_sentiment....50
B.3. Các bảng tổng hợp....50
B.4. Các tập dữ liệu Parquet....51
B.5. Lược đồ file kết quả thực nghiệm....51
B.6. Kết nối và cập nhật dữ liệu....52

LỜI CẢM ƠN

Lời đầu tiên, chúng em xin gửi lời cảm ơn chân thành và sâu sắc nhất đến thầy Nguyễn Văn Chức. Trong suốt quá trình học tập và thực hiện bài tập nhóm môn Nhập môn Dữ liệu lớn, chúng em đã nhận được sự quan tâm, hướng dẫn và định hướng tận tình từ thầy. Những kiến thức quý báu về dữ liệu lớn, xây dựng pipeline, phân tích dữ liệu cũng như các mô hình và thuật toán mà thầy truyền đạt là nền tảng vô cùng quan trọng để nhóm hoàn thành tốt báo cáo này.

Chúng em cũng xin ghi nhận và cảm ơn tinh thần phối hợp, sự nỗ lực của tất cả các thành viên trong suốt quá trình triển khai dự án. Kiến thức là vô hạn trong khi sự tiếp nhận của bản thân vẫn còn những giới hạn nhất định, do đó báo cáo khó tránh khỏi những thiếu sót. Nhóm rất mong nhận được những ý kiến đóng góp từ thầy để đề tài ngày càng được hoàn thiện hơn.

LỜI MỞ ĐẦU

Sự phát triển của công nghệ sinh nhạc và chuyển đổi giọng hát đã tạo thêm nhiều sản phẩm âm nhạc có sự tham gia của trí tuệ nhân tạo trên YouTube. Bình luận của người xem cung cấp nguồn thông tin về nội dung được thảo luận và cảm xúc thể hiện đối với các sản phẩm này. Tuy nhiên, văn bản ngắn, cách diễn đạt phi chuẩn và dữ liệu phát sinh theo thời gian khiến việc tổng hợp thủ công trở nên tốn công sức.

Báo cáo trình bày quy trình thu thập dữ liệu qua YouTube Data API v3, xử lý bằng Apache Spark, phân cụm bình luận bằng GSDMM, diễn giải cụm thành khía cạnh chính và dự đoán cảm xúc chung bằng mô hình tiếng Việt đã được huấn luyện trước. Docker được sử dụng để đóng gói môi trường, Apache Airflow điều phối tác vụ; kết quả được tổ chức trong PostgreSQL và phục vụ dashboard Looker Studio thông qua BigQuery.

Đề tài vận dụng các công nghệ xử lý dữ liệu lớn theo hướng xây dựng quy trình có khả năng mở rộng. Mục tiêu là hỗ trợ tổng hợp phản hồi theo nhóm nội dung và tra cứu bình luận, cung cấp thông tin tham khảo cho người sử dụng. Kết quả được giới hạn trong tập dữ liệu thực nghiệm; đề tài chưa có tập nhãn chuẩn độc lập để xác nhận độ chính xác và không xem các tỷ lệ dự đoán là kết luận đại diện cho toàn bộ khán giả Việt Nam.

Báo cáo gồm sáu chương. Chương 1 giới thiệu đề tài, mục tiêu và phạm vi. Chương 2 trình bày cơ sở lý thuyết và nghiên cứu liên quan. Chương 3 mô tả kiến trúc và phương pháp. Chương 4 trình bày triển khai hệ thống. Chương 5 tổng hợp thực nghiệm và đánh giá. Chương 6 nêu kết luận, hạn chế và hướng phát triển.

CHƯƠNG 1. TỔNG QUAN ĐỀ TÀI

1.1. Giới thiệu đề tài

Sự phát triển của trí tuệ nhân tạo đã mở rộng khả năng ứng dụng công nghệ trong sáng tác và sản xuất âm nhạc. Các sản phẩm âm nhạc có sự tham gia của AI ngày càng đa dạng, từ những bài hát được tạo bằng công cụ sinh nhạc đến nội dung mô phỏng hoặc chuyển đổi giọng hát. YouTube là một nền tảng phổ biến để chia sẻ các sản phẩm này và ghi nhận phản hồi của người nghe thông qua bình luận.

Đề tài "Phân tích phản ứng của khán giả Việt Nam đối với nhạc AI trên YouTube" tập trung khai thác bình luận tiếng Việt nhằm tìm hiểu những nội dung được người xem thảo luận và cảm xúc thể hiện trong các bình luận. Phương pháp được lựa chọn là phân cụm bằng GSDMM, diễn giải cụm thành khía cạnh chính và kết hợp với mô hình phân tích cảm xúc tiếng Việt được huấn luyện trước.

1.1.1. Bối cảnh và lý do chọn đề tài

Các công cụ như Suno, Udio và những công nghệ chuyển đổi giọng hát đã tạo thêm phương thức sản xuất âm nhạc. Người dùng có thể sử dụng mô tả bằng văn bản, lời bài hát hoặc âm thanh tham chiếu để tạo ra sản phẩm có sự hỗ trợ của AI. Những thay đổi này góp phần mở rộng khả năng sáng tạo, đồng thời đặt ra các vấn đề về chất lượng sản phẩm, tính nguyên bản và sự minh bạch trong quá trình sản xuất.

Trên YouTube, phản hồi đối với nhạc AI có thể đề cập đến nhiều nội dung như giai điệu, lời bài hát, phối khí, chất lượng âm thanh hoặc nguồn gốc của tác phẩm. Một số người nghe đánh giá cao trải nghiệm âm nhạc, trong khi những người khác quan tâm đến mức độ tự nhiên của giọng hát hoặc việc ghi nhận đóng góp của các bên liên quan. Việc chỉ thống kê số bình luận tích cực và tiêu cực chưa giúp làm rõ những nhóm nội dung gắn với các phản hồi đó.

Bình luận YouTube thường ngắn, sử dụng cách diễn đạt không chuẩn, từ viết tắt, emoji và đôi khi chứa nội dung không liên quan. Khi dữ liệu tiếp tục phát sinh, việc đọc và tổng hợp thủ công trở nên tốn thời gian. Vì vậy, cần có quy trình hỗ trợ thu thập, làm sạch, tổ chức và phân tích dữ liệu một cách nhất quán.

Nguồn dữ liệu YouTube có tính đa dạng và khả năng cập nhật theo thời gian, tạo điều kiện để vận dụng các công nghệ xử lý dữ liệu lớn. Tuy nhiên, quy mô dữ liệu thực nghiệm của đề tài cần được phân biệt với quy mô tổng thể của nền tảng. Việc sử dụng Apache Spark, Docker và Apache Airflow trong đề tài hướng đến tổ chức quy trình xử

lý có khả năng mở rộng, thay vì chỉ dựa vào số lượng bình luận để khẳng định mức độ lớn của dữ liệu.

Từ những yêu cầu trên, nhóm lựa chọn đề tài nhằm xây dựng quy trình phân tích kết hợp nội dung thảo luận và cảm xúc chung của bình luận. Kết quả được trực quan hóa để hỗ trợ người sử dụng quan sát thống kê tổng hợp và tra cứu các bình luận cụ thể.

1.1.2. Mục tiêu của đề tài

Mục tiêu tổng quát của đề tài là xây dựng quy trình thu thập, xử lý và phân tích bình luận tiếng Việt liên quan đến nhạc AI trên YouTube, từ đó mô tả các nhóm nội dung thảo luận và phân bố cảm xúc trong từng nhóm khía cạnh chính.

Các mục tiêu cụ thể gồm:

- Xây dựng quy trình tìm kiếm và sàng lọc video có dấu hiệu liên quan đến nhạc AI dựa trên từ khóa, siêu dữ liệu và thông tin khai báo có thể truy xuất.
- Thu thập bình luận, siêu dữ liệu video và các snapshot chỉ số tương tác thông qua YouTube Data API v3.
- Làm sạch, chuẩn hóa, khử trùng và tách từ bình luận bằng Apache Spark để tạo dữ liệu phù hợp cho các bước phân tích.
- Sử dụng GSDMM để phân cụm bình luận, diễn giải kết quả và gán một khía cạnh chính cho mỗi bình luận.
- Sử dụng mô hình cảm xúc tiếng Việt được huấn luyện trước để dự đoán cảm xúc chung theo ba nhãn: tích cực, trung lập và tiêu cực.
- Tổ chức lưu trữ kết quả và xây dựng dashboard trên Looker Studio để phân tích quy mô dữ liệu, phân bố khía cạnh, cơ cấu cảm xúc và nội dung bình luận.

Kết quả khía cạnh và cảm xúc được kết hợp để thống kê các bình luận theo từng nhóm nội dung. Đề tài chưa đặt mục tiêu xác định cảm xúc riêng hướng đến từng khía cạnh trong một bình luận có nhiều ý.

1.2. Tổng quan về nguồn dữ liệu

Hệ thống sử dụng YouTube Data API v3 để thu thập dữ liệu công khai phục vụ nghiên cứu. Video được tìm kiếm bằng các từ khóa liên quan đến nhạc AI, kết hợp với những cấu hình tìm kiếm phù hợp với nội dung tiếng Việt. Dữ liệu được tổ chức thành ba nhóm chính.

Nhóm thứ nhất là siêu dữ liệu video, gồm mã video, tiêu đề, mô tả, thông tin kênh, thời điểm đăng và các thuộc tính liên quan có thể truy xuất. Những trường này hỗ trợ lựa chọn đối tượng thu thập và liên kết video với bình luận.

Nhóm thứ hai là dữ liệu bình luận, gồm mã bình luận, mã video, nội dung, thời điểm đăng, lượt thích và quan hệ giữa bình luận gốc với phản hồi. Đây là nguồn văn bản chính để phân cụm và dự đoán cảm xúc. Mã bình luận được sử dụng để nhận diện và khử trùng bản ghi, trong khi mã video hỗ trợ tổng hợp các bình luận thuộc cùng một video.

Nhóm thứ ba là snapshot chỉ số tương tác, gồm lượt xem, lượt thích và số bình luận của video tại thời điểm ghi nhận. Việc lưu kèm mốc thời gian giúp theo dõi thay đổi của các chỉ số và hỗ trợ quản lý quá trình cập nhật dữ liệu.

Việc lựa chọn video dựa trên các tín hiệu như tiêu đề, mô tả, thẻ và thông tin khai báo nội dung tổng hợp khi có. Các tín hiệu này chỉ hỗ trợ nhận diện video có khả năng phù hợp; chúng chưa thay thế việc kiểm chứng trực tiếp nội dung âm thanh hoặc quá trình sản xuất. Một video nhắc đến AI có thể là nội dung hướng dẫn hoặc thảo luận, thay vì một sản phẩm âm nhạc do AI tạo ra.

Dữ liệu bình luận còn có thể chứa quảng cáo, nội dung sao chép, nhiều ngôn ngữ và thảo luận lạc đề. Vì vậy, dữ liệu cần được tiền xử lý trước khi đưa vào mô hình. Quy mô, khoảng thời gian và số lượng bản ghi còn lại sau từng bước xử lý được trình bày trong phần thực nghiệm.

Cần phân biệt dữ liệu được hệ thống thu thập với tập dữ liệu dùng để kiểm thử các bước phân tích. Bộ kết quả cũ được cung cấp cho phần thực nghiệm có dữ liệu đã hợp nhất, gồm cả nội dung giả lập; các thống kê từ bộ này không được mặc nhiên quy thành phản ứng thực tế của toàn bộ khán giả. Nguồn và phạm vi của từng mốc được nêu tại mục 5.1.

1.3. Đối tượng và phạm vi nghiên cứu

Đối tượng nghiên cứu

Đối tượng nghiên cứu là nội dung bình luận tiếng Việt liên quan đến các video nhạc AI được lựa chọn trên YouTube, cùng với siêu dữ liệu và chỉ số tương tác hỗ trợ quá trình thu thập, quản lý dữ liệu.

Phạm vi nội dung

Đề tài quan tâm đến hai nhóm nội dung: AI cover sử dụng công nghệ mô phỏng hoặc chuyển đổi giọng hát, và âm nhạc được tạo ra với sự tham gia của AI trong sáng tác

hoặc sản xuất. Việc lựa chọn video dựa trên các tín hiệu có thể thu thập, chưa đồng nghĩa với việc xác minh toàn bộ video trong tập dữ liệu bằng phân tích âm thanh.

Các khía cạnh phân tích được hình thành thông qua việc diễn giải kết quả phân cụm GSDMM. Mỗi bình luận được gán một khía cạnh chính. Những cụm chưa rõ nghĩa hoặc chưa phù hợp với bộ khía cạnh được gán nhãn "Khác".

Phạm vi khán giả

Đề tài tập trung vào bình luận bằng tiếng Việt trong tập dữ liệu được lựa chọn. Ngôn ngữ bình luận và thông tin liên quan đến video được sử dụng làm căn cứ tham khảo, không mặc định mọi người bình luận đều có quốc tịch hoặc đang cư trú tại Việt Nam.

Do đó, kết quả phản ánh tập bình luận được phân tích, chưa đủ cơ sở để đại diện cho toàn bộ khán giả Việt Nam hoặc toàn bộ người nghe nhạc AI trên YouTube.

Phạm vi dữ liệu phân tích

Hệ thống có thể thu thập cả bình luận gốc và phản hồi. Trong quy trình phân tích của đề tài, các phản hồi được loại ở bước tiền xử lý để tập trung vào bình luận cấp cao nhất. Những bản ghi thiếu thông tin cần thiết, trùng lặp hoặc không đáp ứng các quy tắc lọc cũng được xử lý trước khi đưa vào mô hình.

Thời gian phân tích được xác định theo trường ngày đăng bình luận. Thời điểm này được phân biệt với thời điểm thu thập dữ liệu và thời điểm xử lý của hệ thống.

Phạm vi kỹ thuật

Đề tài sử dụng Apache Spark để tiền xử lý dữ liệu và GSDMM để khám phá các nhóm nội dung trong bình luận. Từ khóa đại diện và bình luận mẫu được sử dụng để diễn giải cụm, xây dựng bảng ánh xạ cụm–khía cạnh và gán một khía cạnh chính cho mỗi bình luận.

Mô hình 5CD-AI/Vietnamese-Sentiment-visobert được sử dụng để dự đoán cảm xúc chung của toàn bộ bình luận. Nhóm sử dụng mô hình cảm xúc có sẵn, không tiền huấn luyện mô hình ngôn ngữ từ đầu. Việc kết hợp khía cạnh và sentiment phục vụ thống kê theo nhóm nội dung, chưa phải mô hình xác định cảm xúc riêng cho từng khía cạnh trong cùng một câu.

Hệ thống được thiết kế để triển khai bằng Docker và điều phối bằng Apache Airflow. Dữ liệu được lưu dưới định dạng Parquet qua các tầng xử lý; kết quả phân tích được tổ chức trong PostgreSQL. Theo phương án trực quan hóa của đề tài, dữ liệu được xuất và tải thủ công lên BigQuery, sau đó kết nối với Looker Studio để xây dựng dashboard.

1.4. Ý nghĩa thực tiễn của đề tài

Đối với nhà sáng tạo nội dung, đề tài cung cấp cách tổng hợp phản hồi của người xem theo những nhóm nội dung thay vì chỉ đọc từng bình luận riêng lẻ. Thống kê khía cạnh và cảm xúc giúp xác định các nhóm thảo luận nổi bật, quan sát sự khác biệt về cơ cấu cảm xúc và lựa chọn những bình luận cần xem xét thêm.

Dashboard hỗ trợ tra cứu theo thời gian, video, khía cạnh và sentiment, đồng thời cho phép đọc nội dung bình luận để đối chiếu với kết quả mô hình. Những thông tin này có thể được sử dụng làm nguồn tham khảo khi đánh giá phản hồi đối với sản phẩm và cân nhắc nội dung cần cải thiện. Chúng chưa trực tiếp chứng minh nhu cầu thị trường hoặc xác định thể loại, giọng hát mà toàn bộ khán giả mong muốn.

Đối với việc tổ chức và xử lý dữ liệu, đề tài minh họa quy trình kết nối từ thu thập qua API, tiền xử lý văn bản, phân tích bằng mô hình đến lưu trữ và trực quan hóa. Cách tổ chức này giúp quản lý các bước xử lý, theo dõi dữ liệu đầu vào–đầu ra và tạo nền tảng để mở rộng hệ thống khi cần.

Về mặt học thuật, đề tài vận dụng phân cụm văn bản ngắn và mô hình cảm xúc tiếng Việt vào một bối cảnh ứng dụng cụ thể. Quá trình thực nghiệm cũng giúp nhận diện những giới hạn của phương pháp, gồm sai lệch trong lựa chọn video, cụm có nội dung lẫn nhau và sai sót khi dự đoán cảm xúc. Đây là cơ sở để đánh giá kết quả và đề xuất các hướng phát triển phù hợp.

CHƯƠNG 2. CƠ SỞ LÝ THUYẾT VÀ NGHIÊN CỨU LIÊN QUAN

2.1. Tổng quan về nhạc AI và dữ liệu YouTube

Nhạc trí tuệ nhân tạo, thường được gọi là nhạc AI, là sản phẩm âm nhạc có sự tham gia của các kỹ thuật trí tuệ nhân tạo trong quá trình sáng tác, tạo giọng hát, phối khí hoặc sản xuất âm thanh. Sự phát triển của các mô hình sinh đã mở rộng khả năng tạo âm nhạc từ những đầu vào như văn bản mô tả, giai điệu hoặc đoạn âm thanh tham chiếu. Nghiên cứu MusicGen của Copet và cộng sự cho thấy khả năng điều khiển quá trình sinh âm nhạc bằng văn bản và giai điệu, minh họa cho hướng phát triển này [1].

Xét theo vai trò của AI trong quá trình sản xuất, có thể phân biệt ba nhóm nội dung. Nhóm thứ nhất là âm nhạc được AI tạo sinh, trong đó hệ thống tạo ra một phần hoặc phần lớn nội dung âm nhạc từ yêu cầu đầu vào. Nhóm thứ hai là nội dung chuyển đổi hoặc mô phỏng giọng hát, thường xuất hiện dưới dạng AI cover. Nhóm thứ ba là sản phẩm do con người thực hiện nhưng có sử dụng AI để hỗ trợ một số công đoạn như viết lời, phối khí hoặc xử lý âm thanh. Các nhóm này có mức độ tham gia của AI khác nhau, vì vậy không nên xem mọi video có nhắc đến AI đều là bài hát được AI tạo ra.

Bên cạnh các vấn đề kỹ thuật, nhạc AI còn tạo ra nhiều thảo luận về chất lượng giọng hát, giai điệu, lời bài hát, tính sáng tạo và quyền lợi của người sáng tác. Người nghe có thể đánh giá cao chất lượng âm thanh nhưng đồng thời đặt câu hỏi về nguồn gốc giọng hát hoặc việc ghi công. Do đó, việc phân tích phản hồi của người nghe cần quan tâm đến cả nội dung được đề cập và cảm xúc thể hiện trong bình luận.

YouTube là một nguồn dữ liệu phù hợp cho hướng nghiên cứu này vì kết hợp nội dung âm thanh, video và phản hồi bằng văn bản. Thông qua YouTube Data API v3, hệ thống có thể truy xuất siêu dữ liệu video, bình luận và một số chỉ số tương tác công khai. Những nhóm tài nguyên liên quan trực tiếp gồm videos, commentThreads và comments [2].

Trong đề tài, dữ liệu YouTube được xem xét theo ba nhóm chính:

Nhóm dữ liệu	Nội dung	Vai trò
Siêu dữ liệu video	Mã video, tiêu đề, mô tả, thông tin kênh, thời điểm đăng	Xác định đối tượng thu thập và liên kết dữ liệu
Bình luận	Mã bình luận, nội dung, tác giả, thời điểm đăng, lượt thích, quan hệ trả lời	Phân tích chủ đề và cảm xúc
Snapshot tương tác	Lượt xem, lượt thích và số bình luận tại thời điểm ghi nhận	Theo dõi biến động tương tác của video

Đơn vị phân tích văn bản chính của đề tài là bình luận. Mỗi bình luận được liên kết với video thông qua mã video_id; mã comment_id được dùng để nhận diện và khử trùng bản ghi. Lượt thích của bình luận phản ánh mức độ tương tác với bình luận đó, khác với lượt thích của video.

Dữ liệu bình luận YouTube có đặc điểm của văn bản mạng xã hội: thường ngắn, sử dụng từ viết tắt, tiếng lóng, emoji và cách diễn đạt không tuân theo văn phong chuẩn. Một số bình luận chứa nhiều ngôn ngữ, nội dung quảng cáo, lời bài hát được sao chép hoặc thảo luận không liên quan. Những đặc điểm này làm tăng yêu cầu đối với quá trình làm sạch và lựa chọn mô hình phân tích.

2.2. Phân tích cảm xúc và phân tích cảm xúc theo khía cạnh

Phân tích cảm xúc là một nhiệm vụ của xử lý ngôn ngữ tự nhiên nhằm nhận diện ý kiến, thái độ hoặc sắc thái đánh giá được thể hiện trong văn bản. Theo Liu, nhiệm vụ này liên quan đến việc phân tích quan điểm của con người đối với các thực thể, sự kiện và thuộc tính của chúng [3].

Tùy theo mức độ chi tiết, phân tích cảm xúc có thể được thực hiện ở cấp tài liệu, cấp câu hoặc cấp khía cạnh. Trong phạm vi bình luận YouTube, cách tiếp cận phổ biến là phân loại toàn bộ bình luận vào các nhóm cảm xúc. Đề tài sử dụng ba nhãn: tích cực, trung lập và tiêu cực. Nhãn tích cực được gán cho những bình luận thể hiện sự yêu thích, hài lòng hoặc đánh giá tốt đối với bài hát, chẳng hạn: “Giai điệu cuốn quá, nghe lại mấy lần.” Nhãn trung lập được gán cho những bình luận chủ yếu cung cấp thông tin hoặc đặt câu hỏi, chưa thể hiện đánh giá rõ ràng, chẳng hạn: “Bài này tạo bằng công cụ nào vậy?” Nhãn tiêu cực được gán cho những bình luận thể hiện sự không hài lòng hoặc đánh giá không tốt, chẳng hạn: “Giọng hát bị méo, nghe khá khó chịu.”

Trong lĩnh vực nhạc AI, những khía cạnh có thể được quan tâm gồm giọng hát, giai điệu, lời bài hát, phối khí, chất lượng âm thanh, tính sáng tạo và sự minh bạch về quá trình sản xuất. Khía cạnh không chỉ là những từ xuất hiện trực tiếp trong câu mà còn có thể được thể hiện gián tiếp. Chẳng hạn, câu “Nghe như người thật vậy” có thể liên quan đến mức độ tự nhiên của giọng hát dù không sử dụng cụm từ “giọng hát”.

Tuy nhiên, cần phân biệt cơ sở lý thuyết ABSA với phương pháp thực hiện trong đề tài. Đề tài sử dụng GSDMM để phân cụm bình luận, diễn giải các cụm thành khía cạnh và gán một khía cạnh chính cho mỗi bình luận. Sau đó, mô hình cảm xúc dự đoán cảm xúc chung của toàn bộ bình luận.

Kết quả kết hợp được biểu diễn dưới dạng:

$$r_i = (c_i, a_i, s_i)$$

Trong đó, ci là bình luận, ai là khía cạnh chính kế thừa từ cụm và si là cảm xúc chung được mô hình dự đoán. Biểu diễn này hỗ trợ thống kê cảm xúc của các bình luận thuộc từng khía cạnh, nhưng chưa đồng nghĩa với việc xác định cảm xúc riêng hướng đến từng khía cạnh trong câu nhiều ý.

2.3. Mô hình chủ đề cho văn bản ngắn và thuật toán GSDMM

Mô hình chủ đề là một hướng tiếp cận nhằm phát hiện những cấu trúc nội dung tiềm ẩn trong tập văn bản dựa trên sự phân bố và đồng xuất hiện của các từ. Thay vì yêu cầu mỗi văn bản phải có nhãn chủ đề từ trước, mô hình khai thác các mẫu thống kê để tìm những nhóm nội dung tương đồng.

Đối với văn bản dài, một tài liệu thường chứa nhiều thông tin và có thể đề cập đến nhiều chủ đề. Ngược lại, bình luận mạng xã hội thường chỉ gồm một vài câu hoặc một số từ. Số lượng từ ít khiến dữ liệu biểu diễn trở nên thưa và làm hạn chế thông tin đồng xuất hiện trong từng văn bản. Vì vậy, việc phân tích chủ đề của bình luận ngắn cần những giả định phù hợp với đặc điểm dữ liệu này.

Dirichlet Multinomial Mixture (DMM) là mô hình hỗn hợp dựa trên giả định mỗi văn bản được sinh ra từ một chủ đề. GSDMM, viết tắt của Gibbs Sampling for the Dirichlet Multinomial Mixture model, là phương pháp sử dụng lấy mẫu Gibbs để suy luận việc gán văn bản vào các chủ đề trong mô hình DMM. Yin và Wang đề xuất cách tiếp cận này cho bài toán phân cụm văn bản ngắn [5].

Giả định mỗi bình luận thuộc một chủ đề chính phù hợp với mục tiêu gán một khía cạnh chính trong đề tài. Tuy nhiên, đây là giả định mô hình nhằm đơn giản hóa bài toán; nó không có nghĩa mọi bình luận thực tế chỉ chứa một ý.

Về nguyên lý, mỗi chủ đề có một phân bố xác suất trên tập từ vựng. Một bình luận được gán vào một chủ đề, sau đó các từ trong bình luận được mô hình hóa dựa trên phân bố từ của chủ đề đó. Các phân bố được điều chỉnh bởi những tham số tiên nghiệm Dirichlet.

Quá trình phân cụm bằng GSDMM có thể được mô tả như sau:

1. Biểu diễn mỗi bình luận thành danh sách token.
2. Khởi tạo ngẫu nhiên cụm cho các bình luận.
3. Lần lượt loại tạm một bình luận khỏi cụm hiện tại.
4. Tính xác suất bình luận thuộc từng cụm dựa trên số văn bản và phân bố từ của cụm.
5. Lấy mẫu cụm mới theo xác suất đã tính.

6. Lặp lại quá trình qua nhiều vòng và thu nhận kết quả phân cụm.

Với dạng tiên nghiệm đối xứng, xác suất có điều kiện dùng trong bước lấy mẫu có thể biểu diễn theo tỷ lệ:

$$P\left(z_d = k \mid z_{-d}, w\right) \propto \left(m_{k,-d} + \alpha\right) \frac{\prod_{w \in d} \prod_{j=0}^{c_d(w)-1} \left(n_{kw,-d} + \beta + j\right)}{\prod_{j=0}^{N_d-1} \left(n_{k,-d} + V\beta + j\right)}$$

- Trong đó:
- zd: cụm được gán cho bình luận d.
- mk,-d: số bình luận trong cụm k, không tính bình luận d.
- nkw,-d: số lần từ w xuất hiện trong cụm k, không tính bình luận d.
- nk,-d: tổng số token của cụm k, không tính bình luận d.
- cd(w): số lần từ w xuất hiện trong bình luận d.
- Nd: tổng số token của bình luận d.
- α, β: các tham số làm trơn cho phân bố cụm và phân bố từ.

,: các tham số làm trơn cho phân bố cụm và phân bố từ.

Công thức thể hiện hai nguồn thông tin chính: mức độ phổ biến của cụm và mức độ phù hợp giữa các từ của bình luận với phân bố từ trong cụm. Các tham số làm trơn giúp duy trì xác suất hợp lệ đối với những cụm hoặc từ có tần suất thấp.

Những tham số quan trọng của thuật toán gồm số cụm tối đa K, các hệ số α, β, số vòng lặp và hạt giống ngẫu nhiên. Số cụm có dữ liệu sau khi chạy có thể nhỏ hơn K. Việc lựa chọn tham số ảnh hưởng đến độ chi tiết, mức độ tập trung và tính ổn định của kết quả.

GSDMM không tự sinh ra các tên khía cạnh như “Giai điệu” hay “Chất lượng âm thanh”. Đầu ra trực tiếp là mã cụm và những từ có tính đại diện cho cụm. Để chuyển kết quả phân cụm thành khía cạnh phục vụ phân tích, cần xem xét từ khóa, đọc bình luận mẫu và xây dựng bảng ánh xạ giữa cụm với tên khía cạnh.

Trong đề tài, mỗi cụm được gán một tên khía cạnh chính; nhiều cụm có thể cùng thuộc một khía cạnh. Những cụm chưa rõ nghĩa hoặc không phù hợp với phạm vi phân tích được gán nhãn “Khác”. Mọi bình luận trong cùng cụm kế thừa tên khía cạnh của cụm đó.

Cách diễn giải này có hạn chế khi cụm chứa nhiều nội dung khác nhau hoặc bình luận đề cập đồng thời nhiều khía cạnh. Ngoài ra, mã cụm không mang ý nghĩa cố định giữa

các lần huấn luyện. Cụm có mã số giống nhau ở hai lần chạy có thể chứa những nội dung khác nhau, vì vậy bảng tên cụm phải được gắn với đúng phiên bản mô hình và lần huấn luyện tương ứng.

2.4. Mô hình ViSoBERT và ứng dụng phân tích cảm xúc tiếng Việt

Các mô hình ngôn ngữ tiền huấn luyện học cách biểu diễn văn bản từ lượng lớn dữ liệu trước khi được áp dụng cho những nhiệm vụ cụ thể. Khác với phương pháp chỉ dựa trên tần suất từ hoặc từ điển cảm xúc, mô hình ngôn ngữ theo ngữ cảnh có thể xây dựng biểu diễn của một từ dựa trên những thành phần xung quanh nó.

BERT là một nghiên cứu tiêu biểu cho hướng tiếp cận này. Devlin và cộng sự giới thiệu mô hình biểu diễn ngôn ngữ hai chiều, cho phép khai thác đồng thời ngữ cảnh bên trái và bên phải của token. Sau giai đoạn tiền huấn luyện, mô hình có thể được tinh chỉnh cho các nhiệm vụ như phân loại văn bản, nhận diện thực thể và trả lời câu hỏi [6].

Đối với tiếng Việt, PhoBERT của Nguyen và Nguyen là một mô hình tiền huấn luyện đơn ngữ quan trọng, cung cấp nền tảng biểu diễn cho nhiều nhiệm vụ xử lý ngôn ngữ tự nhiên [7]. Tuy nhiên, văn bản mạng xã hội có những đặc điểm khác với văn bản biên tập chuẩn, đặc biệt ở cách viết tắt, tiếng lóng, lỗi chính tả và biểu tượng cảm xúc.

ViSoBERT được Nguyen và cộng sự giới thiệu nhằm phục vụ xử lý văn bản mạng xã hội tiếng Việt. Mô hình được tiền huấn luyện theo kiến trúc XLM-R trên dữ liệu mạng xã hội và được khảo sát trên nhiều nhiệm vụ, trong đó có phân tích cảm xúc [8]. Định hướng dữ liệu này tạo cơ sở để xem xét ViSoBERT cho các bình luận YouTube có cách diễn đạt phi chuẩn.

Cần phân biệt mô hình nền ViSoBERT với mô hình đã được tinh chỉnh cho phân tích cảm xúc. Mô hình nền cung cấp khả năng biểu diễn ngôn ngữ; để phân loại cảm xúc, cần sử dụng mô hình có lớp phân loại và đã được huấn luyện cho nhiệm vụ tương ứng.

Trong đề tài, mô hình được sử dụng là 5CD-AI/Vietnamese-Sentiment-visobert, một mô hình phân loại cảm xúc được công bố trên Hugging Face [9]. Đề tài sử dụng mô hình có sẵn để suy luận, không tiền huấn luyện lại ViSoBERT và không mặc nhiên coi kết quả của mô hình trên các bộ dữ liệu khác là độ chính xác trên dữ liệu nhạc AI.

Quá trình dự đoán có thể khái quát thành các bước: chuẩn hóa nhẹ văn bản, mã hóa bằng tokenizer đi kèm mô hình, tính biểu diễn ngữ cảnh, đưa qua lớp phân loại và chuyển điểm đầu ra thành phân bố xác suất bằng hàm softmax. Với ba nhãn cảm xúc, xác suất của nhãn j được tính như sau:

$$P(s=j \mid x)=\frac{\exp(\ell_j)}{\sum_{k=1}^{3}\exp(\ell_k)}$$

Trong đó, x là văn bản đầu vào và lj là điểm đầu ra của mô hình đối với nhãn j. Nhãn có xác suất lớn nhất được chọn làm kết quả dự đoán:

$$\hat{s}=arg\ \max_{j\in\{1,2,3\}} P(s=j \mid x)$$

Đầu vào của mô hình cảm xúc là văn bản bình luận, khác với danh sách token dùng cho GSDMM. Với mô hình chủ đề, từ dừng và dấu câu có thể được loại bỏ nhằm tập trung vào nội dung. Với mô hình cảm xúc, từ phủ định, cách viết và emoji có thể ảnh hưởng đến ý nghĩa câu nên cần được giữ lại phù hợp. Tokenizer của mô hình cảm xúc thực hiện việc mã hóa đầu vào theo cơ chế riêng; token của tokenizer không đồng nhất với từ đã tách bằng công cụ xử lý tiếng Việt.

Mô hình cũng có giới hạn về độ dài đầu vào. Khi bình luận vượt quá độ dài cấu hình, một phần văn bản phải được cắt trước khi suy luận. Nếu thông tin đánh giá quan trọng nằm ở cuối câu, kết quả dự đoán có thể bị ảnh hưởng. Vì vậy, cần ghi nhận các trường hợp bị cắt để phục vụ đánh giá.

2.5. Các nghiên cứu liên quan và khoảng trống nghiên cứu

Các nghiên cứu liên quan đến đề tài có thể được xem xét theo ba hướng: mô hình chủ đề cho văn bản ngắn, phân tích cảm xúc tiếng Việt và phân tích cảm xúc theo khía cạnh. Ngoài ra, nghiên cứu về sinh âm nhạc cung cấp bối cảnh cho đối tượng nội dung được khảo sát.

Nghiên cứu	**Đóng góp liên quan**	**Ý nghĩa đối với đề tài**
Yin và Wang, 2014 [5]	Đề xuất phương pháp phân cụm văn bản ngắn dựa trên DMM và lấy mẫu Gibbs	Cơ sở lựa chọn GSDMM cho bình luận ngắn
Pontiki và cộng sự, 2014 [4]	Xây dựng các nhiệm vụ đánh giá ABSA	Cơ sở phân biệt khía cạnh và cảm xúc hướng đến khía cạnh
Devlin và cộng sự, 2019 [6]	Đề xuất BERT với biểu diễn ngữ cảnh hai chiều	Nền tảng lý thuyết cho mô hình ngôn ngữ tiền huấn luyện
Nguyen và Nguyen, 2020 [7]	Phát triển PhoBERT cho tiếng Việt	Cho thấy vai trò của mô hình tiền huấn luyện theo ngôn ngữ
Nguyen và cộng sự, 2023 [8]	Phát triển ViSoBERT cho văn bản mạng xã hội tiếng Việt	Cơ sở lựa chọn mô hình biểu diễn phù hợp với bình luận mạng xã hội

Nghiên cứu	Đóng góp liên quan	Ý nghĩa đối với đề tài
Copet và cộng sự, 2023 [1]	Nghiên cứu sinh âm nhạc có điều khiển bằng văn bản và giai điệu	Cung cấp bối cảnh về sự phát triển của âm nhạc tạo sinh

Các nghiên cứu về GSDMM cho thấy cách khai thác cấu trúc nội dung của văn bản ngắn khi chưa có bộ nhãn chủ đề đầy đủ. Tuy nhiên, kết quả phân cụm vẫn cần được diễn giải theo lĩnh vực ứng dụng. Trong bối cảnh nhạc AI, những cụm liên quan đến âm thanh, lời bài hát hoặc tính sáng tạo không tự động có sẵn tên gọi chỉ từ quá trình suy luận thống kê.

Các mô hình ngôn ngữ như PhoBERT và ViSoBERT cung cấp nền tảng cho phân tích văn bản tiếng Việt. Dù vậy, sự phù hợp với ngôn ngữ và loại văn bản không đảm bảo mô hình sẽ nhận diện chính xác mọi sắc thái trong bình luận về nhạc AI. Những cách nói liên quan đến chất giọng “máy móc”, sự giống người thật hoặc các tranh luận về nguồn gốc tác phẩm có thể tạo ra thách thức khi chuyển mô hình sang lĩnh vực này.

Trong khi đó, ABSA cung cấp cách tiếp cận chi tiết cho những câu chứa nhiều đối tượng đánh giá. Việc xây dựng một hệ thống ABSA chuyên biệt thường cần dữ liệu gán nhãn khía cạnh và cảm xúc tương ứng. Đây là yêu cầu khác với việc kết hợp nhãn cụm GSDMM và nhãn cảm xúc chung của câu.

Từ phạm vi tài liệu được tham khảo, đề tài xác định nhu cầu ứng dụng ở ba điểm. Thứ nhất là tổ chức dữ liệu bình luận YouTube để có thể liên kết nội dung văn bản với video và thời gian đăng. Thứ hai là kết hợp phân cụm văn bản ngắn với mô hình cảm xúc tiếng Việt nhằm mô tả đồng thời nội dung thảo luận và sắc thái đánh giá. Thứ ba là chuyển kết quả xử lý thành dữ liệu có thể truy vấn và trực quan hóa, giúp người sử dụng xem xét cả thống kê tổng hợp lẫn bình luận cụ thể.

Trên cơ sở đó, đề tài lựa chọn GSDMM để phát hiện các nhóm nội dung, diễn giải mỗi nhóm thành khía cạnh chính và sử dụng mô hình cảm xúc dựa trên ViSoBERT để phân loại toàn bộ bình luận. Đóng góp được định hướng ở việc xây dựng và đánh giá quy trình ứng dụng cho dữ liệu nghiên cứu, thay vì đề xuất thuật toán GSDMM mới hoặc mô hình ABSA mới.

Phạm vi này cũng đặt ra các giới hạn cần được xem xét trong thực nghiệm: độ chính xác của việc lựa chọn video, mức độ nhất quán của các cụm, sai lệch khi một bình luận có nhiều khía cạnh và khả năng tổng quát hóa của mô hình cảm xúc. Các khoảng trống nêu trên được hiểu là nhu cầu cần giải quyết trong bài toán ứng dụng của đề tài, không phải khẳng định rằng chưa từng có nghiên cứu về cảm xúc đối với nhạc AI.

CHƯƠNG 3. KIẾN TRÚC HỆ THỐNG VÀ PHƯƠNG PHÁP ĐỀ XUẤT

3.1. Kiến trúc tổng quan hệ thống

Hệ thống được thiết kế nhằm xây dựng quy trình thu thập, tiền xử lý, phân tích và trực quan hóa bình luận YouTube liên quan đến nhạc AI. Kiến trúc đề xuất sử dụng Docker để đóng gói môi trường thực thi, Apache Airflow để điều phối các tác vụ, Apache Spark để xử lý dữ liệu và các mô hình xử lý ngôn ngữ tự nhiên để phân tích nội dung bình luận.

Docker giúp quản lý các thành phần và thư viện trong những môi trường riêng biệt, hạn chế khác biệt cấu hình giữa các máy. Apache Airflow tổ chức các nhiệm vụ thành đồ thị có hướng không chu trình, xác định thứ tự phụ thuộc, theo dõi trạng thái và hỗ trợ thực hiện lại khi tác vụ thất bại.

Luồng xử lý được chia thành bốn giai đoạn:

Giai đoạn 1: Ingestion - Thu thập dữ liệu

Hệ thống sử dụng YouTube Data API v3 để tìm kiếm video theo các từ khóa liên quan đến nhạc AI, thu thập thông tin video, bình luận và snapshot chỉ số tương tác. Quá trình thu thập có cơ chế phân trang, kiểm soát ngân sách gọi API và lưu tiến độ để tiếp tục trong những lần chạy sau.

Giai đoạn 2: Preprocessing - Tiền xử lý dữ liệu

Apache Spark được sử dụng để chuẩn hóa cấu trúc, chuyển đổi kiểu dữ liệu, xử lý bản ghi thiếu thông tin, loại bình luận trả lời và giảm dữ liệu trùng lặp. Các quy tắc ngôn ngữ và nội dung được áp dụng nhằm hạn chế những bình luận không phù hợp với phạm vi phân tích.

Giai đoạn 3: Modeling - Phân cụm và phân tích cảm xúc

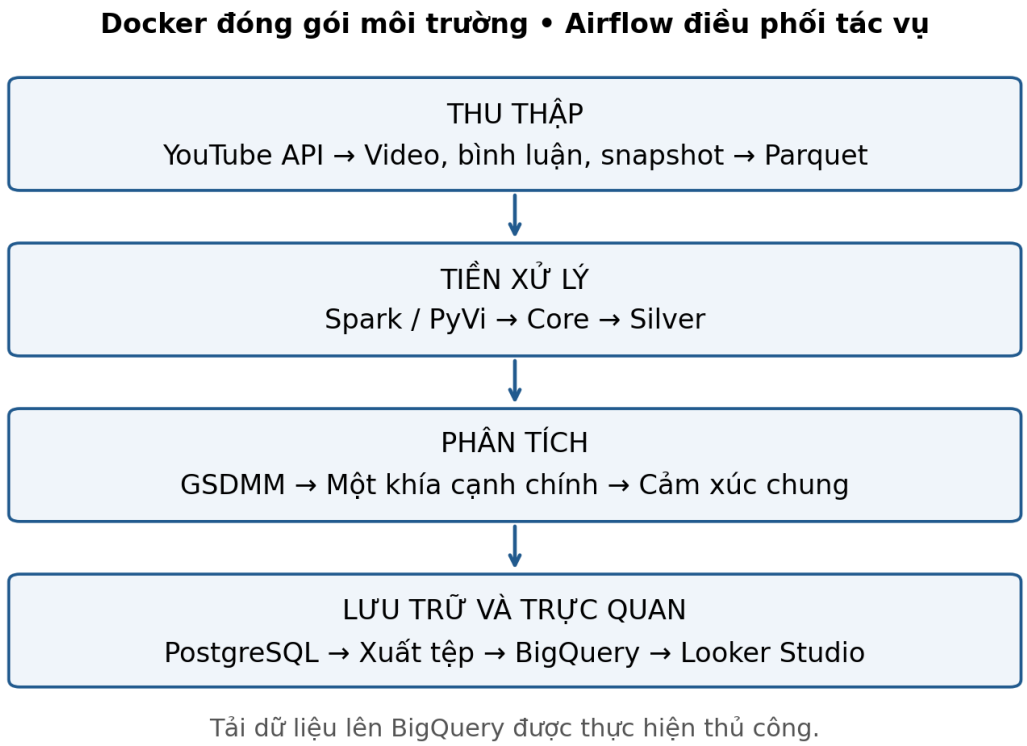
GSDMM được sử dụng để phân nhóm bình luận dựa trên đặc trưng từ vựng. Từ khóa đặc trưng và bình luận mẫu của từng cụm được xem xét để xây dựng bảng ánh xạ cụm sang khía cạnh. Mỗi bình luận nhận một khía cạnh chính thông qua cụm chứa nó; những cụm chưa xác định được nội dung phù hợp được gán nhãn Khác.

Mô hình tiếng Việt được huấn luyện trước, 5CD-AI/Vietnamese-Sentiment-visobert, được sử dụng để dự đoán cảm xúc chung của từng bình luận theo ba lớp: tích cực, trung lập và tiêu cực.

Giai đoạn 4: Visualization - Phục vụ truy vấn và trực quan hóa

Sau khi hoàn tất phân tích, kết quả được lưu dưới định dạng Parquet và nạp vào PostgreSQL để tổ chức bảng chi tiết cùng các bảng tổng hợp. Người thực hiện xuất dữ liệu cần thiết thành tệp CSV hoặc Parquet phù hợp với phương thức nạp, rồi tải thủ công lên BigQuery. Looker Studio kết nối với bảng BigQuery để xây dựng dashboard về quy mô dữ liệu, khía cạnh, cảm xúc, thời gian đăng và nội dung bình luận. DAG hiện hành kết thúc ở spark_mart; bước tải BigQuery chưa được tự động hóa.

Luồng dữ liệu tổng quát được thể hiện như sau:



Hình 3.1. Kiến trúc tổng quan và luồng dữ liệu

3.2. Phương pháp thu thập dữ liệu tự động

Hệ thống sử dụng YouTube Data API v3 để thu thập thông tin video, bình luận và các chỉ số tương tác. Các tác vụ được triển khai trong môi trường Docker và điều phối bằng Apache Airflow, giúp thực hiện quy trình theo lịch, ghi nhận trạng thái và thử lại khi xảy ra lỗi.

Quá trình tìm kiếm sử dụng các từ khóa liên quan đến nhạc AI, bài hát do AI tạo, giọng hát AI và các công cụ như Suno, Udio. Tham số khu vực Việt Nam và ngôn ngữ tiếng Việt được sử dụng để định hướng kết quả tìm kiếm. Hệ thống kết hợp tìm video mới với truy vấn các khoảng thời gian trong quá khứ, đồng thời lưu tiến độ để tiếp tục ở những lần chạy sau. Tuy nhiên, thông tin tìm kiếm và metadata chỉ cung cấp dấu hiệu về mức độ liên quan, không bảo đảm toàn bộ video được tạo bằng AI hoặc được sản xuất tại Việt Nam.

Đối với các video được theo dõi, hệ thống thu thập bình luận thông qua cơ chế phân trang của API. Dữ liệu gồm mã bình luận, mã video, nội dung, thông tin người viết, lượt thích, thời điểm đăng và quan hệ giữa bình luận gốc với phản hồi. Mã bình luận và thời điểm cập nhật được sử dụng để hạn chế việc ghi lại các bản ghi không thay đổi. Việc quét lại được ưu tiên cho video chưa thu thập hoặc có số bình luận tăng, kết hợp xét độ tuổi video và thời điểm quét gần nhất.

Ngoài bình luận, Airflow lập lịch thu thập snapshot gồm lượt xem, lượt thích và tổng số bình luận của video. Mỗi snapshot gắn với thời điểm thu thập, tạo thành chuỗi quan sát phục vụ phân tích biến động tương tác. Các truy vấn thông tin video được gom theo lô để giảm số lần gọi API. Khi đạt ngân sách truy vấn hoặc hết quota, hệ thống ghi nhận trạng thái và tiếp tục ở lần chạy sau. Dữ liệu thu thập được lưu dưới định dạng Parquet trước khi chuyển sang bước tiền xử lý.

3.3. Quy trình tiền xử lý dữ liệu

Quy trình tiền xử lý sử dụng Apache Spark để chuẩn hóa dữ liệu, giảm trùng lặp và hạn chế nội dung không phù hợp với mục tiêu phân tích. Dữ liệu được xử lý qua hai bước chính: chuẩn hóa tại tầng Core và lựa chọn tập bình luận phân tích tại tầng Silver.

Ở tầng Core, hệ thống chuẩn hóa tên trường, kiểu dữ liệu và các mốc thời gian. Những bản ghi trùng mã bình luận được đối chiếu để giữ bản cập nhật phù hợp. Nội dung ban đầu được lưu trong trường text_raw, đồng thời tạo hai biểu diễn phục vụ các bước xử lý tiếp theo:

- text_clean: văn bản đã giải mã ký tự HTML, loại thẻ HTML, URL, lượt nhắc tên và mốc thời gian trong nội dung; đồng thời chuẩn hóa Unicode, chữ thường, ký tự kéo dài và khoảng trắng.
- tokens: danh sách từ sau khi tách từ tiếng Việt bằng PyVi, loại dấu câu, emoji, số thuần túy và các từ dừng theo cấu hình.

Việc duy trì các biểu diễn riêng giúp giữ nội dung để đối chiếu, đồng thời cung cấp danh sách từ phù hợp với mô hình chủ đề. Đặc biệt, danh sách tokens không được dùng làm đầu vào trực tiếp cho mô hình cảm xúc vì bước loại từ dừng có thể làm mất từ phủ định và những tín hiệu quan trọng khác.

Ở tầng Silver, chương trình clean_comments.py lựa chọn bình luận phục vụ phân tích. Các bước gồm loại bình luận trả lời, bản ghi thiếu mã định danh, nội dung bị null, danh sách từ bị thiếu và bản ghi trùng mã bình luận. Giá trị lượt thích được chuyển về kiểu số, còn thời gian đăng được chuẩn hóa để sử dụng trong thống kê.

Tiếp theo, hệ thống sử dụng dấu hiệu ngôn ngữ và các mẫu từ để giảm bình luận ngoại ngữ, nội dung toán học và một số nhóm nội dung lạc đề. Bình luận quá ngắn được xem xét theo điều kiện độ dài văn bản. Đối với nội dung dài bị lặp nguyên văn, hệ thống giữ một bản đại diện; những bình luận ngắn trùng nội dung có thể được giữ lại nếu thuộc các mã bình luận khác nhau. Các quy tắc này có tính chất heuristic, vì vậy không thể loại bỏ hoàn toàn nhiễu và có thể bỏ sót một số bình luận phù hợp. Trong cấu hình đang mô tả, điều kiện độ dài là tối thiểu 3 từ phân tách bằng khoảng trắng; nội dung dài từ 8 từ trở lên được khử trùng theo văn bản chuẩn hóa. Điều kiện này khác với số token còn lại sau bước từ điển của GSDMM.

Kết quả Silver gồm bảy trường:

Trường	Nội dung
comment_id	Mã định danh bình luận
video_id	Mã video chứa bình luận
author	Mã kênh của người viết, nếu có
text	Nội dung bình luận giữ lại từ text_raw
likes	Số lượt thích của bình luận tại thời điểm thu thập
published	Thời gian hoặc ngày đăng được chuẩn hóa
tokens	Danh sách từ dùng cho mô hình chủ đề

Trường văn bản chuẩn hóa tạm thời trong bước lọc không thay thế nội dung text. Những bình luận bị loại bởi quy tắc lạc đề được lưu thành báo cáo riêng để hỗ trợ kiểm tra. Kết quả Silver mới chỉ thay thế tập dữ liệu đang sử dụng sau khi quá trình xử lý và ghi dữ liệu hoàn tất.

3.4. Phương pháp phân cụm, gán khía cạnh chính và dự đoán cảm xúc

Phương pháp đề xuất kết hợp mô hình chủ đề với mô hình phân tích cảm xúc tiếng Việt. GSDMM được sử dụng để hình thành các cụm bình luận có đặc điểm từ vựng tương đồng. Nhóm nghiên cứu diễn giải các cụm và xây dựng bảng ánh xạ từ mã cụm sang khía cạnh. Sau đó, mô hình cảm xúc dự đoán sắc thái chung của từng bình luận.

Theo phạm vi đề tài, mỗi bình luận được gán một khía cạnh chính và một nhãn cảm xúc chung. Hai kết quả được kết hợp để thống kê phản hồi theo khía cạnh. Phương pháp này không thực hiện trích xuất nhiều khía cạnh hoặc xác định cảm xúc riêng cho từng đối tượng trong cùng một câu.

3.4.1. Phân cụm bình luận bằng GSDMM

GSDMM là mô hình chủ đề phù hợp với văn bản ngắn, dựa trên giả định mỗi văn bản thuộc một chủ đề chính. Trong hệ thống, mỗi bình luận được xem là một văn bản, còn danh sách tokens là biểu diễn đầu vào.

Trước khi huấn luyện, chương trình xây dựng từ điển từ các từ xuất hiện trong tập bình luận và loại những từ có tần suất thấp hơn ngưỡng cấu hình. Mỗi bình luận được biểu diễn bằng các mã từ cùng số lần xuất hiện tương ứng. Các bình luận không còn đủ từ hợp lệ sau bước xây dựng từ điển không được dùng để ước lượng mô hình.

Cấu hình thực nghiệm ban đầu sử dụng số cụm tối đa K=20, hai tham số $\alpha = 0,1$ và $\beta = 0,1$, 30 vòng lặp và hạt giống ngẫu nhiên bằng 42. Trong quá trình Gibbs sampling, chương trình lần lượt cập nhật cụm của từng bình luận dựa trên quy mô cụm và phân bố từ trong cụm. Số cụm thực sự có dữ liệu có thể nhỏ hơn số cụm tối đa được thiết lập.

Sau huấn luyện, hệ thống lưu trạng thái mô hình, từ điển, kết quả gán cụm và danh sách từ nổi bật. Các từ nổi bật và bình luận đại diện là cơ sở để diễn giải nội dung từng cụm. Kết quả phân cụm mang tính khám phá, không mặc nhiên tương ứng với bộ nhãn khía cạnh đã được xác định trước.

Đối với vận hành định kỳ, hệ thống sử dụng phương án huấn luyện và diễn giải một phiên bản mô hình trước, sau đó giữ cố định mô hình để gán cụm cho dữ liệu ở các lần chạy tiếp theo. Cách này giúp duy trì ý nghĩa của mã cụm và bảng ánh xạ khía cạnh. Bình luận có quá ít từ thuộc từ điển để gán cụm được đưa vào nhóm Khác. Khi cần huấn luyện lại, mô hình và bảng ánh xạ phải được kiểm tra như một phiên bản mới.

3.4.2. Diễn giải cụm và gán một khía cạnh chính cho mỗi bình luận

Sau khi phân cụm, nhóm nghiên cứu xem xét danh sách từ nổi bật kết hợp với nội dung các bình luận đại diện để xác định chủ đề chính của từng cụm. Trên cơ sở đó, một bảng ánh xạ được xây dựng giữa mã cụm và nhãn khía cạnh.

Các khía cạnh có thể gồm giai điệu, phối khí và nhạc cụ, chất lượng âm thanh, lời bài hát và cảm xúc, trải nghiệm nghe, sáng tạo và phong cách, quy trình và chỉnh sửa, hoặc minh bạch và ghi công. Những cụm thể hiện phản hồi chung được gán nhãn tương ứng; cụm không rõ chủ đề hoặc không phù hợp với phạm vi phân tích được đưa vào Khác.

Việc gán khía cạnh cho bình luận được thực hiện theo quan hệ: Khía cạnh của bình luận = Nhãn khía cạnh được ánh xạ từ cụm của bình luận

Theo đó, các bình luận trong cùng một cụm kế thừa cùng nhãn khía cạnh. Một khía cạnh có thể tương ứng với nhiều cụm nếu các cụm thể hiện những nhóm từ vựng khác nhau nhưng cùng nội dung chính.

Cách tiếp cận này giúp giảm khối lượng gán nhãn thủ công cho toàn bộ dữ liệu. Tuy nhiên, cụm có thể chứa nội dung hỗn hợp, nên nhãn kế thừa chưa bảo đảm chính xác cho từng bình luận. Nếu một bình luận đề cập đồng thời nhiều vấn đề, hệ thống chỉ giữ khía cạnh đại diện theo cụm được gán. Đây là giới hạn của phương pháp một khía cạnh chính cho mỗi bình luận.

3.4.3. Dự đoán cảm xúc chung bằng mô hình được huấn luyện trước

Hệ thống sử dụng mô hình 5CD-AI/Vietnamese-Sentiment-visobert để dự đoán cảm xúc tiếng Việt. Đây là mô hình phân loại cảm xúc được tinh chỉnh từ ViSoBERT, trả về ba nhóm nhãn: Tích cực, Trung lập và Tiêu cực. Trong phạm vi đề tài, mô hình được sử dụng để suy luận, không huấn luyện lại trên tập bình luận thu thập.

Đầu vào của bước này là trường text, được giữ lại từ nội dung bình luận gốc sau bước lựa chọn dữ liệu. Trước khi đưa vào mô hình, chương trình giải mã ký tự HTML, loại thẻ HTML và URL, đồng thời chuẩn hóa khoảng trắng. Bước này không áp dụng danh sách từ dừng của GSDMM và không chuyển toàn bộ văn bản sang chữ thường, nhằm giữ các tín hiệu như từ phủ định, dấu câu và emoji.

Văn bản được bộ tokenizer của mô hình chuyển thành chuỗi token và xử lý theo lô. Cấu hình sử dụng độ dài tối đa 128 token của mô hình; những bình luận vượt giới hạn được cắt ngắn và đánh dấu bằng trường sentiment_truncated. Token của mô hình cảm xúc khác với các từ đã tách bằng PyVi trong trường tokens.

Nhãn có điểm đầu ra lớn nhất được chọn làm cảm xúc dự đoán. Chương trình đồng thời lưu điểm của cả ba nhãn và điểm của nhãn được chọn để phục vụ kiểm tra. Các điểm này là đầu ra softmax của mô hình, không được hiểu là độ chính xác đã được xác nhận trên tập dữ liệu nghiên cứu.

Kết quả phản ánh cảm xúc chung của bình luận. Một câu tích cực chưa chắc thể hiện sự ủng hộ nhạc AI, và một câu tiêu cực có thể phản ánh cảm xúc về lời bài hát hoặc một sự việc được nhắc đến.

3.4.4. Kết hợp kết quả khía cạnh và cảm xúc để phân tích

Kết quả phân cụm, khía cạnh và cảm xúc được kết hợp theo comment_id. Mỗi dòng tương ứng với một bình luận duy nhất, chứa mã cụm, một khía cạnh chính và một nhãn cảm xúc chung. Nhóm Khác vẫn được giữ lại và được dự đoán cảm xúc theo cùng quy trình, không tự động chuyển thành Trung lập.

Tập kết quả hỗ trợ thống kê số lượng bình luận, cơ cấu cảm xúc theo khía cạnh, phân bố thảo luận theo video và diễn biến theo thời gian. Tỷ lệ một nhãn cảm xúc trong khía cạnh được tính bằng:

$$P(s \mid a) = \frac{N_{a,s}}{N_a} \times 100\%$$

Trong đó, Na,s là số bình luận thuộc khía cạnh a có nhãn cảm xúc s, còn Na là tổng số bình luận của khía cạnh đó. Khi diễn giải tỷ lệ, cần xem xét đồng thời số lượng bình luận để tránh kết luận từ những nhóm có quy mô quá nhỏ.

Kết quả được sử dụng để mô tả cảm xúc chung của các bình luận được gán vào từng khía cạnh. Hệ thống chưa xác định cảm xúc riêng hướng đến từng khía cạnh trong một câu, vì vậy các thống kê này không được xem là kết quả ABSA đầy đủ.

3.5. Thiết kế hệ thống lưu trữ và cơ sở dữ liệu

Hệ thống kết hợp lưu trữ tệp Parquet với cơ sở dữ liệu PostgreSQL. Parquet phục vụ lưu dữ liệu thu thập và các kết quả trung gian; PostgreSQL phục vụ quản lý bảng phân tích và truy vấn tổng hợp. Các thư mục dữ liệu được gắn vào container thông qua Docker volumes hoặc bind mounts để các thành phần sử dụng chung dữ liệu.

Cấu trúc lưu trữ được tổ chức theo vai trò xử lý:

Vị trí lưu trữ	Vai trò
data/staging/	Dữ liệu trích từ API hoặc nhập từ nguồn cũ, tổ chức theo ngày tiếp nhận
data/core/	Dữ liệu đã chuẩn hóa, hợp nhất và xử lý trùng lặp
data/silver/comments_clean/	Tập bình luận được lựa chọn để phân tích
data/models/gsdmm_v1/	Mô hình GSDMM, từ điển và bảng ánh xạ khía cạnh của một phiên bản
data/gold/	Kết quả phân cụm, gán khía cạnh, cảm xúc và báo cáo kiểm tra
data/business/	Tập kết quả hiện hành để nạp vào PostgreSQL

Đường dẫn gsdmm_v1 được hình thành khi chuẩn bị phiên bản mô hình, không phải dữ liệu mô hình có sẵn mặc định. Việc lưu mô hình cùng bảng ánh xạ giúp hạn chế sử dụng nhầm tên khía cạnh giữa các lần huấn luyện.

Tại PostgreSQL, cơ sở dữ liệu ytb_mart sử dụng ba bảng chính:

Bảng	Nội dung và khóa chính
fact_comment_sentiment	Kết quả phân tích từng bình luận; khóa chính comment_id

Bảng	Nội dung và khóa chính
agg_aspect_sentiment	Tổng hợp số lượng và tỷ lệ cảm xúc theo khía cạnh; khóa chính gồm aspect, sentiment
agg_video_sentiment	Tổng hợp số lượng và tỷ lệ cảm xúc theo video; khóa chính gồm video_id, sentiment

Bảng chi tiết lưu các trường cần thiết cho truy vấn như mã bình luận, mã video, mã cụm, khía cạnh, cảm xúc, điểm dự đoán, thời gian đăng, lượt thích bình luận và nội dung. Các biểu diễn phục vụ mô hình như danh sách tokens tiếp tục được giữ trong tệp Parquet, không bắt buộc nạp vào bảng phục vụ dashboard.

Mã video_id cho phép đối chiếu bình luận với thông tin video và các snapshot tương tác. Trong đó, likes của bình luận cần được phân biệt với lượt thích video trong bảng snapshot. Snapshot sử dụng mã video kết hợp với mốc thời gian để mô tả sự thay đổi chỉ số qua các lần thu thập.

Sau khi hoàn tất xử lý và kiểm tra, dữ liệu từ PostgreSQL được xuất thành tệp để tải thủ công lên BigQuery. Looker Studio kết nối với bảng BigQuery để xây dựng dashboard tổng quan, phân tích khía cạnh và cảm xúc, cùng bảng tra cứu bình luận. Việc cập nhật dashboard phụ thuộc vào lần xuất và tải dữ liệu gần nhất; quy trình này chưa thực hiện đồng bộ tự động từ PostgreSQL sang BigQuery.

CHƯƠNG 4. THIẾT KẾ VÀ TRIỂN KHAI HỆ THỐNG

4.1. Môi trường và công nghệ sử dụng

Hệ thống được triển khai trên máy tính cá nhân sử dụng Windows, kết hợp Docker Desktop với nền tảng WSL2 để vận hành các container Linux. Mã nguồn được quản lý bằng Git và GitHub, đồng thời sử dụng Visual Studio Code để chỉnh sửa chương trình, cấu hình và theo dõi quá trình thực thi.

Các thành phần được tổ chức bằng Docker Compose, gồm PostgreSQL, các dịch vụ Apache Airflow và hai container thực thi mô hình GSDMM, sentiment. Việc sử dụng container giúp quản lý thư viện theo từng thành phần và giảm xung đột giữa môi trường điều phối với môi trường xử lý mô hình.

Các công nghệ chính được sử dụng như sau:

Công nghệ	Vai trò trong hệ thống
Python	Xây dựng chương trình thu thập, xử lý dữ liệu và thực thi mô hình
Docker Desktop và Docker Compose	Đóng gói môi trường, cấu hình và vận hành các dịch vụ
Apache Airflow 3.3.2	Lập lịch, điều phối tác vụ, theo dõi trạng thái và nhật ký
YouTube Data API v3	Thu thập thông tin video, bình luận và chỉ số tương tác
Apache Spark 4.1.3	Chuẩn hóa, hợp nhất, lọc và xử lý dữ liệu
PyVi	Tách từ tiếng Việt để tạo đầu vào cho GSDMM
NumPy, Pandas và PyArrow	Xử lý dữ liệu dạng bảng, thực thi GSDMM và đọc ghi Parquet
PyTorch và Transformers	Nạp và chạy mô hình phân tích cảm xúc
PostgreSQL 16	Lưu bảng kết quả chi tiết và các bảng tổng hợp
BigQuery	Lưu dữ liệu được tải lên thủ công để phục vụ dashboard
Looker Studio	Trực quan hóa và tương tác với kết quả phân tích

Airflow sử dụng LocalExecutor để thực thi tác vụ. Các dịch vụ chính gồm API server cung cấp giao diện quản trị, scheduler lập lịch và DAG processor xử lý định nghĩa luồng công việc. PostgreSQL lưu metadata của Airflow và dữ liệu phân tích trong hai cơ sở dữ liệu riêng: airflow và ytb_mart.

Hai container ytb-gsdmm-runner và ytb-sentiment-runner cung cấp môi trường riêng cho các bước mô hình hóa. Airflow gọi chương trình trong các container này thông qua Docker SDK. Vì vậy, container thực thi tác vụ Airflow cần được gắn Docker

socket, còn các container mô hình cần được gắn đúng thư mục mã nguồn và dữ liệu dùng chung.

Cấu hình được quản lý bằng tệp .env đặt tại thư mục gốc dự án. Tệp này chứa API key YouTube, thông tin kết nối PostgreSQL, tài khoản quản trị Airflow, các khóa bảo mật và tham số xử lý. Thông tin đăng nhập thực tế được tách khỏi mã nguồn và không đưa lên repository công khai.

Thư mục data/ trên máy được gắn vào các container để chia sẻ dữ liệu. Cùng một tập dữ liệu có thể được truy cập qua đường dẫn /opt/airflow/data trong Airflow và /opt/data trong container mô hình. Cách tổ chức này cho phép chuyển dữ liệu giữa các bước mà không phải sao chép thủ công qua từng container.

Đối với trực quan hóa, dữ liệu sau xử lý được lưu vào PostgreSQL, xuất thành tệp và tải thủ công lên BigQuery. Looker Studio sử dụng bảng BigQuery làm nguồn dữ liệu; bước cập nhật này chưa được tự động hóa trong luồng Airflow.

4.2. Triển khai module thu thập dữ liệu

Module thu thập được tổ chức trong thư mục ytb/, với các thành phần chính gồm discover.py, snapshot.py và comments.py. Cấu hình dùng chung được đặt trong config.py; việc gọi API, quản lý ngân sách truy vấn và lưu dữ liệu được hỗ trợ bởi các module riêng.

Thành phần	Chức năng
config.py	Khai báo từ khóa, phạm vi tìm kiếm, chu kỳ quét và ngân sách truy vấn
youtube_client.py	Khởi tạo API client, thực hiện truy vấn và quản lý quota
discover.py	Tìm kiếm video và thu thập metadata
snapshot.py	Ghi nhận chỉ số tương tác của video theo thời gian
comments.py	Thu thập bình luận gốc và phản hồi
storage.py	Đọc ghi dữ liệu Parquet và trạng thái thu thập

4.2.1. Thu thập thông tin video

Chương trình discover.py thực hiện tìm kiếm bằng các từ khóa được khai báo trong config.py. Các truy vấn sử dụng tham số khu vực Việt Nam, ngôn ngữ tiếng Việt và giới hạn thời gian đăng để định hướng kết quả.

Quá trình tìm kiếm gồm hai phần: tìm video mới trong khoảng thời gian gần nhất và thu thập bổ sung dữ liệu quá khứ theo từng cửa sổ thời gian. Tiến độ truy vấn quá khứ được lưu lại để lần chạy tiếp theo tiếp tục từ vị trí trước đó.

Kết quả được đối chiếu bằng video_id để hạn chế ghi trùng video đã biết. Hệ thống thu thập metadata phục vụ theo dõi và đánh giá mức độ liên quan, gồm thông tin định danh, tiêu đề, mô tả, kênh và thời điểm đăng. Các dấu hiệu từ metadata chỉ hỗ trợ lựa chọn video, chưa xác minh trực tiếp âm thanh có được tạo bằng AI hay không.

4.2.2. Thu thập snapshot tương tác

Chương trình snapshot.py truy vấn các video đã được ghi nhận để lấy lượt xem, lượt thích và tổng số bình luận. Mỗi bản ghi được bổ sung snapshot_date và snapshot_at, giúp phân biệt các lần quan sát của cùng một video.

Danh sách video được chia thành các lô tối đa 50 mã cho mỗi truy vấn thông tin video. Những video đã có snapshot trong ngày được bỏ qua khi tác vụ chạy lại, nhằm hạn chế truy vấn và ghi dữ liệu lặp. Trường hợp video không còn truy cập được hoặc thiếu một chỉ số, chương trình ghi nhận tình trạng thay vì tự gán giá trị tương tác bằng không.

Các snapshot được lưu nối tiếp, tạo cơ sở so sánh chỉ số tương tác giữa các thời điểm. Tổng số bình luận do API trả về ở bước này được phân biệt với số bình luận thực tế đã thu thập và số bình luận còn lại sau tiền xử lý.

4.2.3. Thu thập bình luận

Chương trình comments.py ưu tiên video chưa được quét, sau đó xét các video có tổng số bình luận tăng. Việc quét lại phụ thuộc vào độ tuổi video và thời gian từ lần thu thập gần nhất, giúp tập trung ngân sách vào những video còn phát sinh thảo luận.

Bình luận được lấy qua cơ chế phân trang. Đối với luồng thảo luận có phản hồi, chương trình thực hiện truy vấn bổ sung để thu thập các phản hồi khi cần. Những trường chính gồm mã bình luận, mã video, mã luồng, mã bình luận cha, nội dung, mã kênh người viết, lượt thích và thời điểm đăng hoặc cập nhật.

Quan hệ giữa bình luận gốc và phản hồi được biểu diễn bằng thread_id, parent_id và is_reply. Module thu thập vẫn ghi nhận cả hai loại; việc loại phản hồi khỏi tập phân tích được thực hiện ở bước tiền xử lý.

Chương trình đối chiếu mã bình luận cùng thông tin cập nhật để hạn chế lưu lại dữ liệu không thay đổi. Trạng thái quét được ghi nhận, hỗ trợ lựa chọn video và tiếp tục thu thập trong các lần chạy sau.

4.2.4. Điều phối và lưu trữ

Các bước thu thập được khai báo trong DAG youtube_ai_music_daily tại tệp dags/youtube_ai_music_daily.py, theo thứ tự:

validate_ml_runtime → discover_videos → snapshot_stats
→ fetch_comments → spark_core → spark_business → spark_mart

Task validate_ml_runtime kiểm tra Docker, các container thực thi mô hình và tính toàn vẹn của gói GSDMM cố định. Các task tiếp theo lần lượt thu thập, xử lý và nạp PostgreSQL. Airflow quản lý quan hệ phụ thuộc, nhật ký và cơ chế thử lại khi tác vụ thất bại. Lịch khai báo hiện tại là 20:00 mỗi ngày theo múi giờ Asia/Ho_Chi_Minh, với catchup=False và tối đa một DAG run hoạt động.

Dữ liệu video, snapshot và bình luận được ghi vào data/staging/ dưới định dạng Parquet, tổ chức theo ngày tiếp nhận. Tiến độ và trạng thái quét được lưu riêng trong data/state/. Khi đạt ngân sách truy vấn hoặc hết quota, chương trình ghi nhận nguyên nhân dừng để hỗ trợ theo dõi và tiếp tục ở lần chạy tiếp theo.

Cách triển khai này tách việc thu thập khỏi tiền xử lý và mô hình hóa, đồng thời vẫn duy trì các bước trong cùng một luồng điều phối Airflow. Dữ liệu tại tầng staging được giữ làm đầu vào để có thể xử lý lại khi thay đổi quy tắc làm sạch hoặc phương pháp phân tích.

4.3. Triển khai GSDMM, gán khía cạnh và dự đoán cảm xúc

Module phân tích được tổ chức trong thư mục gsdmm_sentiment, gồm các chương trình xử lý dữ liệu, phân cụm, gán khía cạnh và dự đoán cảm xúc. Airflow điều phối các bước thông qua task spark_business, trong khi các chương trình mô hình được thực thi trong container riêng.

Các thành phần chính gồm:

Thành phần	Chức năng
jobs/clean_comments.py	Lựa chọn và làm sạch tập bình luận phục vụ phân tích
jobs/gsdmm_train.py	Huấn luyện GSDMM, lưu mô hình và gán cụm bằng mô hình cố định
jobs/assign_aspects.py	Hỗ trợ xây dựng bảng ánh xạ cụm sang khía cạnh
jobs/predict_sentiment.py	Dự đoán cảm xúc chung của từng bình luận
ytb/spark_business.py	Kết nối các bước xử lý và tạo kết quả phân tích hiện hành
ytb/ml_containers.py	Gọi chương trình trong các container mô hình qua Docker SDK

4.3.1. Chuẩn bị dữ liệu đầu vào

Hàm build_silver() trong spark_business.py gọi chức năng xử lý của clean_comments.py để tạo tập bình luận tại data/silver/comments_clean/. Tập này

chứa mã bình luận, mã video, thông tin người viết, nội dung, lượt thích, thời gian đăng và danh sách từ đã tách.

Hai trường được sử dụng cho các mục đích khác nhau: tokens làm đầu vào cho GSDMM, còn text cung cấp nội dung cho bước dự đoán cảm xúc và tra cứu kết quả. Các mã định danh được giữ xuyên suốt để đối chiếu giữa những giai đoạn xử lý.

4.3.2. Huấn luyện và lưu phiên bản GSDMM

Chương trình gsdmm_train.py xây dựng từ điển từ danh sách tokens, chuyển mỗi bình luận thành biểu diễn tần suất từ và thực hiện Gibbs sampling. Cấu hình ban đầu sử dụng số cụm tối đa bằng 20, hai tham số $\alpha = \beta = 0{,}1$, 30 vòng lặp và hạt giống ngẫu nhiên bằng 42.

Trong quá trình chạy, chương trình ghi nhận số bình luận đổi cụm và số cụm có dữ liệu ở mỗi vòng. Sau huấn luyện, kết quả được xuất thành tệp bình luận có mã cụm, danh sách từ nổi bật của từng cụm và trạng thái mô hình. Các thông tin này hỗ trợ kiểm tra nội dung cụm và tái sử dụng mô hình.

Phiên bản mô hình được tổ chức trong thư mục data/models/gsdmm_v1/. Thư mục này được tạo trong quá trình chuẩn bị mô hình, chứa trạng thái GSDMM, từ điển, danh sách từ nổi bật, bảng ánh xạ khía cạnh và thông tin kiểm tra phiên bản.

4.3.3. Diễn giải cụm và thiết lập nhãn khía cạnh

Sau lần huấn luyện ban đầu, nhóm nghiên cứu xem xét từ nổi bật và bình luận đại diện để xác định nội dung chính của từng cụm. Chương trình assign_aspects.py hỗ trợ chuẩn bị và áp dụng bảng ánh xạ giữa mã cụm với nhãn khía cạnh.

Bảng ánh xạ được lưu trong tệp cluster_aspects.json đi kèm phiên bản mô hình. Những cụm có nội dung không rõ ràng hoặc không phù hợp với phạm vi nghiên cứu được gán nhãn Khác. Các bình luận kế thừa nhãn từ cụm được gán, bảo đảm mỗi bình luận chỉ có một khía cạnh chính.

Bước diễn giải được thực hiện ở cấp cụm, không yêu cầu gán nhãn thủ công toàn bộ bình luận. Tuy nhiên, các bình luận cùng cụm có thể khác nhau về nội dung cụ thể, vì vậy nhãn khía cạnh vẫn cần được kiểm tra qua những bình luận đại diện.

4.3.4. Gán cụm trong các lần chạy định kỳ

Sau khi mô hình và bảng ánh xạ được kiểm tra, các lần chạy định kỳ sử dụng chế độ dự đoán của gsdmm_train.py. Chương trình đối chiếu từ của bình luận với từ điển đã lưu và tính điểm phù hợp với các cụm hiện có. Quá trình này giữ cố định trạng thái mô hình, giúp duy trì ý nghĩa của mã cụm và nhãn khía cạnh giữa các lần chạy.

Bình luận còn ít hơn 2 token thuộc từ điển được gán cluster = -1 và aspect = Khác, đồng thời vẫn được chuyển sang dự đoán cảm xúc. Mô hình cố định giữ nguyên các

thống kê đã học; bản ghi tham chiếu không đổi có thể giữ mã cụm ban đầu. Khi huấn luyện lại, cần tạo phiên bản và diễn giải lại bảng ánh xạ. Luồng hiện tại xử lý tập Silver hiện hành, chưa phải cơ chế chỉ suy luận các bình luận mới bằng bộ nhớ đệm lâu dài.

Kết quả gán khía cạnh được lưu trong comments_with_aspects.parquet, mỗi dòng tương ứng với một bình luận và có thêm các trường cluster, aspect.

4.3.5. Dự đoán cảm xúc

Chương trình predict_sentiment.py đọc dữ liệu đã gán khía cạnh và sử dụng mô hình 5CD-AI/Vietnamese-Sentiment-visobert để phân loại cảm xúc thành ba nhãn: Tích cực, Trung lập và Tiêu cực.

Trường text được xử lý nhẹ bằng cách giải mã ký tự HTML, loại thẻ HTML, URL và chuẩn hóa khoảng trắng. Chương trình không sử dụng danh sách từ dừng của GSDMM để xử lý đầu vào cảm xúc, nhằm giữ những yếu tố như từ phủ định, dấu câu và emoji.

Dữ liệu được dự đoán theo lô trên CPU. Cấu hình mặc định sử dụng kích thước lô bằng 16 và độ dài đầu vào tối đa 128 token của mô hình. Những bình luận vượt giới hạn được cắt ngắn và ghi nhận trong trường sentiment_truncated.

Chương trình giữ các cột đầu vào và bổ sung kết quả:

Trường	**Ý nghĩa**
sentiment	Nhãn cảm xúc được dự đoán
sentiment_score	Điểm của nhãn được chọn
sentiment_negative	Điểm đầu ra cho nhãn tiêu cực
sentiment_neutral	Điểm đầu ra cho nhãn trung lập
sentiment_positive	Điểm đầu ra cho nhãn tích cực
sentiment_truncated	Đánh dấu văn bản bị cắt ngắn khi dự đoán

Kết quả được xuất thành comments_sentiment.parquet, tệp CSV và bảng tổng hợp cảm xúc theo khía cạnh. Báo cáo thực thi ghi nhận số dòng đầu vào, số dòng được dự đoán, phân bố nhãn, số bình luận bị cắt ngắn và thông tin phiên bản mô hình.

4.3.6. Tích hợp vào Airflow

Trong luồng định kỳ, task spark_business thực hiện lần lượt việc tạo Silver, gán cụm bằng mô hình cố định, ánh xạ khía cạnh và dự đoán cảm xúc. Các kết quả được lưu theo từng đợt trong data/gold/, sau đó tạo tập dữ liệu hiện hành tại data/business/fact_comment_sentiment.parquet để phục vụ bước nạp PostgreSQL.

Bước spark_mart nạp vào bảng tạm PostgreSQL, kiểm tra số dòng rồi mới thay bảng chi tiết và dựng lại các bảng tổng hợp trong cùng giao dịch.

Các bước xử lý giữ nguyên quan hệ một bình luận – một khía cạnh chính – một cảm xúc chung. Kết quả cảm xúc không được hiểu là cảm xúc riêng hướng đến khía cạnh hoặc thái độ chắc chắn đối với nhạc AI. Nhóm Khác vẫn được dự đoán cảm xúc và giữ lại trong tập kết quả.

4.4. Xây dựng dashboard trực quan hóa

Dashboard được thiết kế bằng Looker Studio, sử dụng dữ liệu phân tích được tải lên BigQuery. Mục tiêu là thể hiện quy mô dữ liệu, phân bố khía cạnh, cơ cấu cảm xúc và hỗ trợ tra cứu những bình luận cụ thể.

Các trường chính phục vụ dashboard gồm comment_id, video_id, text, likes, published, aspect và sentiment. Những trường này đã có trong kết quả xử lý; các chỉ số trên biểu đồ được tính bằng phép tổng hợp từ dữ liệu, không cần bổ sung thông tin ngoài tập kết quả.

Dashboard được tổ chức thành ba trang.

Trang 1 – Tổng quan

Trang tổng quan cung cấp thông tin về quy mô tập bình luận và cơ cấu cảm xúc. Năm thẻ KPI thể hiện tổng số bình luận, số video có bình luận trong tập phân tích và tỷ lệ của ba nhãn cảm xúc.

Tổng bình luận được tính theo số comment_id phân biệt; số video được tính theo số video_id phân biệt. Các tỷ lệ cảm xúc được tính trên tập bình luận nằm trong phạm vi bộ lọc hiện tại.

Biểu đồ donut thể hiện cơ cấu cảm xúc, biểu đồ thanh ngang thể hiện số bình luận theo khía cạnh và biểu đồ đường mô tả lượng bình luận theo ngày hoặc tuần. Bộ lọc thời gian và khía cạnh giúp người xem thay đổi phạm vi quan sát.

Biểu đồ thời gian phản ánh thời điểm đăng của những bình luận được phân tích, không đại diện cho toàn bộ hoạt động của YouTube hoặc số bình luận mới mà hệ thống thu thập trong ngày.

Trang 2 – Phân tích khía cạnh và cảm xúc

Trang này tập trung so sánh phản hồi giữa các khía cạnh. Biểu đồ thanh chồng 100% thể hiện tỷ lệ tích cực, trung lập và tiêu cực trong từng khía cạnh. Biểu đồ thanh ngang bổ sung số bình luận tiêu cực theo khía cạnh để người xem đối chiếu tỷ lệ với quy mô thực tế.

Bảng tổng hợp hiển thị tên khía cạnh, tổng số bình luận và tỷ lệ của ba nhãn cảm xúc. Các hàng được sắp xếp hoặc lọc để hỗ trợ nhận diện nhóm được thảo luận nhiều và nhóm có mức phản hồi tiêu cực đáng chú ý.

Nhóm Khác được giữ trong chế độ hiển thị mặc định nhằm phản ánh đầy đủ tập dữ liệu. Người xem có thể loại nhóm này bằng bộ lọc khi cần tập trung vào các khía cạnh cụ thể. Khi diễn giải, tỷ lệ cảm xúc luôn được xem xét cùng số lượng bình luận và giới hạn của phương pháp gán nhãn theo cụm.

Trang 3 – Video và bình luận chi tiết

Trang chi tiết hỗ trợ xác định video có nhiều thảo luận trong tập phân tích và đọc nội dung làm cơ sở giải thích các thống kê.

Biểu đồ Top 10 video sử dụng video_id để hiển thị số bình luận thuộc từng video. Chỉ số này phản ánh số bình luận trong tập dữ liệu sau xử lý, không phải tổng số bình luận công khai của video trên YouTube.

Bảng chi tiết gồm thời gian đăng, mã video, nội dung bình luận, khía cạnh, cảm xúc và lượt thích bình luận. Người xem có thể lọc theo video, khía cạnh, cảm xúc, thời gian hoặc tìm từ khóa trong nội dung. Bảng cho phép sắp xếp theo lượt thích để lựa chọn các bình luận minh họa.

Dashboard không hiển thị tên video, lượt xem hoặc lượt thích video nếu nguồn dữ liệu được kết nối chưa có những trường này. Trường likes được sử dụng ở đây là lượt thích của bình luận.

CHƯƠNG 5. THỰC NGHIỆM VÀ ĐÁNH GIÁ

5.1. Thống kê và mô tả dữ liệu thu thập

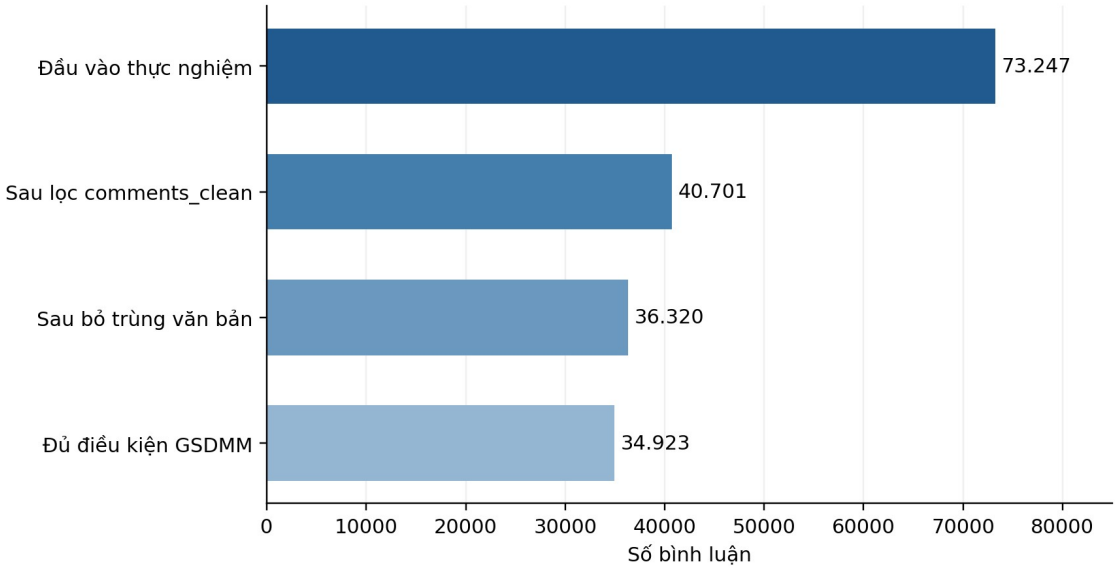
Theo thống kê nhóm cung cấp, dữ liệu thô gồm 92.625 bản ghi bình luận thuộc 2.054 video. Các con số này được ghi nhận riêng với tập đầu vào thực nghiệm và chưa được đối chiếu bằng file thô trong bản rà soát. Phần thực nghiệm dưới đây sử dụng tập test.parquet gồm 73.247 bình luận thuộc 1.851 video, có ngày đăng từ 29/08/2026 đến 21/10/2026.

Tập 73.247 dòng đã được hợp nhất từ dữ liệu thực tế và dữ liệu giả lập dùng cho kiểm thử quy trình. Vì vậy, không xem đây là kết quả lọc trực tiếp từ 92.625 dòng, không quy chênh lệch 19.378 dòng cho một thao tác chưa được xác minh và không coi toàn bộ tỷ lệ cảm xúc là phản ứng thực tế thuần túy của người dùng YouTube. Các kết quả trong chương được giới hạn ở tập thực nghiệm này.

Quy mô dữ liệu tại các mốc xử lý được tổng hợp trong Bảng 5.1.

Bảng 5.1. Quy mô dữ liệu qua các giai đoạn

Mốc dữ liệu	Bình luận	Video	Nguồn/giới hạn đối chiếu
Dữ liệu thô do nhóm thống kê	92.625	2.054	Số nhóm cung cấp; chưa đối chiếu file thô trong bản rà soát
Tập đầu vào thực nghiệm đã hợp nhất	73.247	1.851	File test.parquet đã cung cấp
Sau clean_comments.py	40.701	1.488	File Silver 7 cột đã cung cấp
Sau loại trùng văn bản trong GSDMM	36.320	—	Log GSDMM cũ
Đủ điều kiện huấn luyện GSDMM	34.923	1.468	Log GSDMM cũ
Kết quả khía cạnh và cảm xúc	34.923	1.468	File sentiment cũ



Hình 5.1. Quy mô các mốc đã đối chiếu của tập thực nghiệm

Trong tập đầu vào 73.247 dòng, có 62.868 bình luận gốc và 10.379 bình luận trả lời. Các mã bình luận không bị trùng trong file đầu vào đã kiểm tra.

Chương trình clean_comments.py loại bình luận trả lời, bản ghi thiếu nội dung hoặc danh sách từ và các bản ghi trùng mã bình luận. Tiếp theo, chương trình lọc theo dấu hiệu tiếng Việt, nội dung toán học và độ dài văn bản tối thiểu. Bình luận dài lặp nguyên văn và một số nhóm nội dung lạc đề tiếp tục được xử lý để giảm nhiễu. Sau các bước này, tập dữ liệu còn 40.701 bình luận, giảm 32.546 dòng so với đầu vào.

Trong bước chuẩn bị GSDMM, chương trình tiếp tục loại 4.381 bình luận trùng văn bản chuẩn hóa, đưa số dòng xuống 36.320. Sau khi xây dựng từ điển và kiểm tra số từ hợp lệ còn lại trong mỗi bình luận, 1.397 dòng không đáp ứng điều kiện được loại khỏi tập huấn luyện. Tập phân tích cuối cùng gồm 34.923 bình luận.

Việc tách các mốc trên giúp phân biệt giữa kết quả làm sạch dữ liệu và dữ liệu thực sự được mô hình sử dụng. Số lượng bình luận giảm không đồng nghĩa toàn bộ các dòng bị loại đều không có giá trị; một số dòng chỉ chưa phù hợp với điều kiện đầu vào của phương pháp phân cụm.

5.2. Kết quả phân cụm GSDMM và gán nhãn khía cạnh

GSDMM được thực nghiệm trên tập 34.923 bình luận sau bước chuẩn bị dữ liệu. Danh sách từ đã tách được sử dụng để xây dựng từ điển và biểu diễn tần suất từ cho từng bình luận.

Cấu hình của lần chạy được tổng hợp trong Bảng 5.2.

Bảng 5.2. Cấu hình thực nghiệm GSDMM

Tham số	Giá trị
Số cụm tối đa K	20
Tham số α	0,1
Tham số β	0,1
Số vòng lặp	30
Hạt giống ngẫu nhiên	42
Tần suất từ tối thiểu	2
Số lần xuất hiện của từ hợp lệ tối thiểu trong một bình luận	2
Kích thước từ điển	7.080
Số bình luận huấn luyện	34.923

Sau 30 vòng lặp, mô hình duy trì 20 cụm có dữ liệu. Số bình luận đổi cụm giảm từ 32.173 ở vòng đầu xuống 5.541 ở vòng cuối. Kết quả cho thấy mức thay đổi giảm dần trong quá trình lấy mẫu. Tuy nhiên, ở vòng cuối vẫn còn bình luận chuyển cụm, nên chưa đủ cơ sở khẳng định mô hình đã hội tụ hoàn toàn.

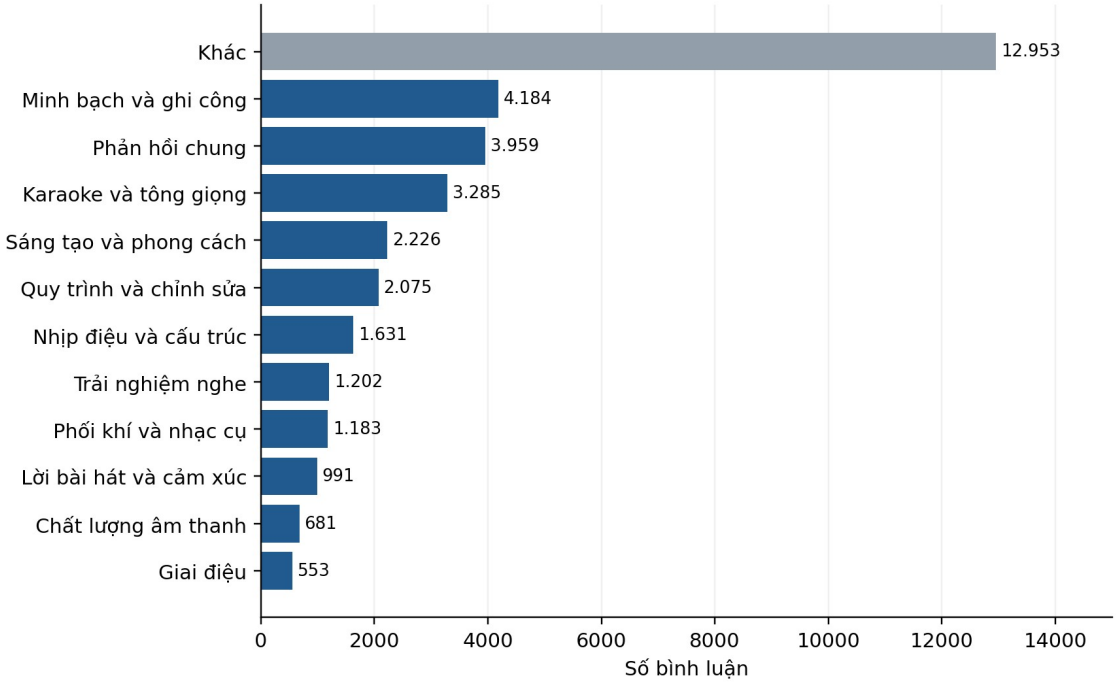
Nhóm nghiên cứu sử dụng các từ nổi bật và bình luận đại diện để diễn giải từng cụm, sau đó ánh xạ thành các nhóm khía cạnh. Theo phạm vi đề tài, mỗi bình luận kế thừa một khía cạnh chính từ cụm được gán. Những cụm chưa rõ nội dung hoặc không phù hợp với phạm vi phân tích được đưa vào nhóm Khác.

Bảng 5.3. Phân bố bình luận theo nhóm khía cạnh

Nhóm khía cạnh	Số bình luận	Tỷ lệ
Khác	12.953	37,09%
Minh bạch và ghi công	4.184	11,98%
Phản hồi chung	3.959	11,34%
Karaoke và tông giọng	3.285	9,41%
Sáng tạo và phong cách	2.226	6,37%
Quy trình và chỉnh sửa	2.075	5,94%
Nhịp điệu và cấu trúc	1.631	4,67%
Trải nghiệm nghe	1.202	3,44%
Phối khí và nhạc cụ	1.183	3,39%
Lời bài hát và cảm xúc	991	2,84%
Chất lượng âm thanh	681	1,95%
Giai điệu	553	1,58%

Nhóm khía cạnh	Số bình luận	Tỷ lệ
Tổng	34.923	100%

Nguồn: tổng hợp từ file comments_sentiment.parquet của bộ kết quả cũ. Tỷ lệ từng nhóm được làm tròn độc lập.



Hình 5.2. Phân bố bình luận theo nhóm khía cạnh

Kết quả gồm 11 nhóm có tên khía cạnh hoặc nội dung phản hồi cụ thể, cùng nhóm Khác. Trong các nhóm ngoài Khác, Minh bạch và ghi công có số bình luận lớn nhất, tiếp theo là Phản hồi chung và Karaoke và tông giọng.

Nhóm Khác chiếm 37,09%, cho thấy một phần đáng kể dữ liệu chưa được diễn giải thành các khía cạnh cụ thể. Tỷ lệ này phản ánh giới hạn của việc đặt nhãn ở cấp cụm và tính đa dạng của nội dung bình luận. Không thể mặc định toàn bộ nhóm Khác là bình luận vô ích hoặc hoàn toàn không liên quan.

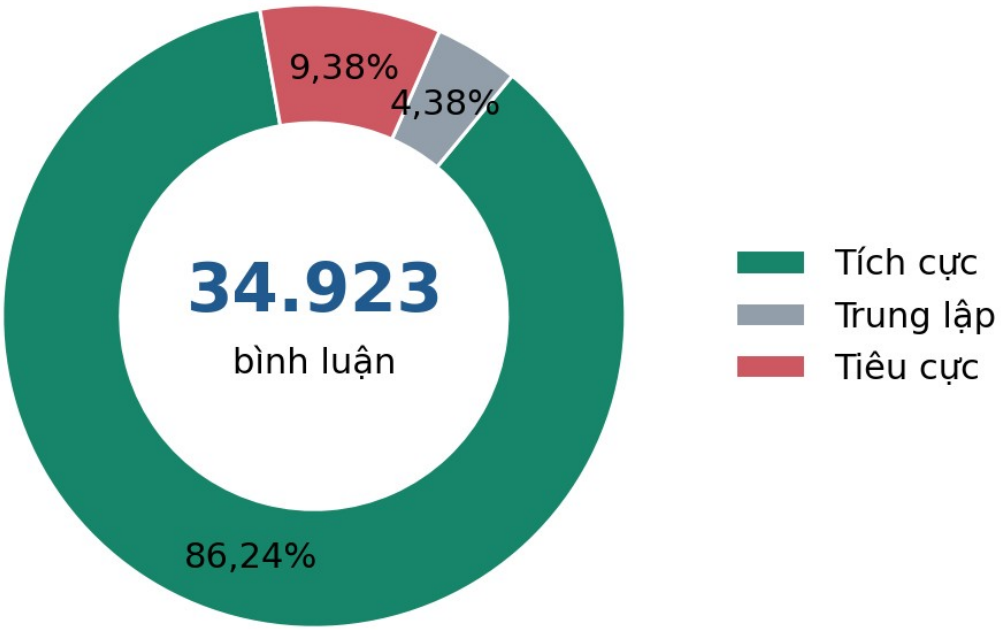
Kết quả phân cụm cũng chịu ảnh hưởng của phân bố bình luận giữa các video. Theo log thực nghiệm, video có nhiều bình luận nhất chiếm khoảng 5,2%, còn 10 video đứng đầu chiếm khoảng 23,9% tập huấn luyện. Do đó, đặc điểm của một số video có nhiều thảo luận có thể ảnh hưởng đến nội dung các cụm.

5.3. Kết quả phân tích cảm xúc theo các nhóm khía cạnh

Mô hình 5CD-AI/Vietnamese-Sentiment-visobert được sử dụng để dự đoán cảm xúc chung của 34.923 bình luận. Toàn bộ các dòng đầu vào đều được xử lý, không có bình luận rỗng ở bước dự đoán cảm xúc.

Bảng 5.4. Phân bố cảm xúc trên toàn bộ tập phân tích

Cảm xúc	Số bình luận	Tỷ lệ
Tích cực	30.118	86,24%
Trung lập	1.528	4,38%
Tiêu cực	3.277	9,38%
Tổng	34.923	100%



Hình 5.3. Cơ cấu cảm xúc của tập thực nghiệm

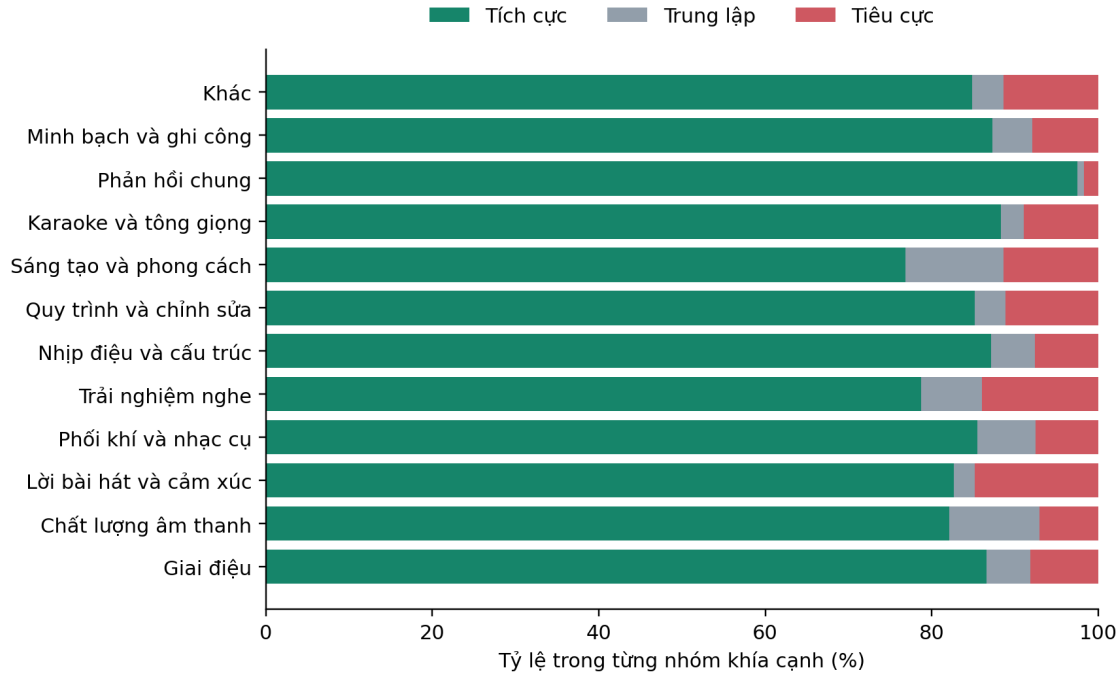
Cảm xúc tích cực chiếm ưu thế trong tập thực nghiệm. Tuy nhiên, tỷ lệ này là kết quả dự đoán trên tập dữ liệu đã lựa chọn và xử lý, không phải tỷ lệ khán giả ủng hộ nhạc AI trên YouTube.

Khi kết hợp với nhãn khía cạnh, kết quả được tổng hợp như Bảng 5.5. Tỷ lệ tiêu cực được tính trên tổng số bình luận của từng nhóm.

Bảng 5.5. Phân bố cảm xúc theo nhóm khía cạnh

Nhóm khía cạnh	Tổng	Tích cực	Trung lập	Tiêu cực	Tỷ lệ tiêu cực
Khác	12.953	10.992	484	1.477	11,40%
Minh bạch và ghi công	4.184	3.652	200	332	7,93%
Phản hồi chung	3.959	3.861	30	68	1,72%
Karaoke và tông giọng	3.285	2.900	91	294	8,95%
Sáng tạo và phong cách	2.226	1.710	262	254	11,41%

Nhóm khía cạnh	Tổng	Tích cực	Trung lập	Tiêu cực	Tỷ lệ tiêu cực
Quy trình và chỉnh sửa	2.075	1.768	76	231	11,13%
Nhịp điệu và cấu trúc	1.631	1.421	86	124	7,60%
Trải nghiệm nghe	1.202	946	88	168	13,98%
Phối khí và nhạc cụ	1.183	1.011	83	89	7,52%
Lời bài hát và cảm xúc	991	819	25	147	14,83%
Chất lượng âm thanh	681	559	74	48	7,05%
Giai điệu	553	479	29	45	8,14%
Tổng	34.923	30.118	1.528	3.277	9,38%



Hình 5.4. Cơ cấu cảm xúc trong từng nhóm khía cạnh

Nhóm Phản hồi chung có tỷ lệ tích cực cao nhất, đạt 97,52%. Trong các nhóm có tên cụ thể, Lời bài hát và cảm xúc có tỷ lệ tiêu cực cao nhất, đạt 14,83%, tiếp theo là Trải nghiệm nghe với 13,98%.

Khi xét số lượng tuyệt đối, nhóm Minh bạch và ghi công có 332 bình luận tiêu cực, cao hơn các nhóm có tên cụ thể còn lại. Kết quả này cho thấy cần xem đồng thời tỷ lệ và quy mô: một nhóm có tỷ lệ tiêu cực thấp hơn vẫn có thể chứa nhiều bình luận tiêu cực hơn nếu tổng số bình luận lớn.

Các thống kê trên phản ánh cảm xúc chung của những bình luận được gán vào từng nhóm. Chẳng hạn, một bình luận tiêu cực thuộc nhóm Lời bài hát và cảm xúc có thể bộc lộ nỗi buồn theo nội dung bài hát, thay vì chê chất lượng lời bài hát. Vì vậy, chưa thể diễn giải toàn bộ nhãn tiêu cực thành sự không hài lòng đối với khía cạnh tương ứng.

5.4. Kiểm tra tính nhất quán dữ liệu và hoạt động của quy trình

Việc kiểm tra được thực hiện ở mức cấu trúc, số lượng bản ghi, khóa định danh và khả năng truy vết giữa các file của bộ thực nghiệm cũ. Các kết quả này được phân biệt với đánh giá độ chính xác ngữ nghĩa của mô hình.

Nội dung kiểm tra	Kết quả trên bộ thực nghiệm
Số dòng kết quả cuối	34.923
Số mã bình luận phân biệt	34.923; không trùng ID
Số video phân biệt	1.468
Các trường comment_id, video_id, text, aspect, sentiment	Không có giá trị null trong file kết quả đã đối chiếu
Đầu vào và đầu ra sentiment	34.923 → 34.923 dòng
Tổng ba nhãn	30.118 + 1.528 + 3.277 = 34.923
Bình luận vượt giới hạn độ dài	179 dòng; khoảng 0,51%
Bảo toàn đầu vào sentiment	Hash SHA-256 trước và sau giống nhau theo báo cáo cũ
Đối chiếu các file	Toàn bộ ID trong file cuối có trong comments_clean và test.parquet

Mã video, nội dung và lượt thích của những bình luận tương ứng được giữ nhất quán giữa file đầu vào và file cuối. Kết quả này hỗ trợ truy vết các bản ghi và cho thấy bước dự đoán cảm xúc không làm mất dòng trong tập được xử lý. Các trường hợp bị cắt ngắn được đánh dấu bằng sentiment_truncated để phục vụ kiểm tra ngữ cảnh.

Ở phiên bản triển khai mới, validate_ml_runtime kiểm tra Docker, các container mô hình và tính toàn vẹn của gói GSDMM. Bước nạp PostgreSQL đưa dữ liệu vào bảng tạm, đối chiếu số dòng với Business rồi mới thay bảng chính và dựng lại bảng tổng hợp trong cùng giao dịch. Nếu phát sinh lỗi, giao dịch được rollback. Đây là cơ chế bảo vệ trong code; việc xác nhận một lần chạy hoàn tất vẫn cần log của chính lần chạy đó.

Bộ kết quả cũ chứng minh các bước chuẩn bị dữ liệu, phân cụm, gán khía cạnh và dự đoán cảm xúc đã tạo được đầu ra. Chưa sử dụng bằng chứng của các lần chạy định kỳ mới để thay thế cho số liệu thực nghiệm cũ. Báo cáo chưa lượng hóa độ ổn định qua nhiều ngày, khả năng mở rộng hoặc tốc độ trên các cấu hình phần cứng khác nhau.

Đề tài chưa có tập nhãn chuẩn độc lập để tính precision, recall và F1-score cho khía cạnh hoặc sentiment. Điểm softmax không được xem là độ chính xác đã kiểm chứng. Các phép kiểm tra số dòng và khóa định danh chỉ xác nhận tính nhất quán dữ liệu, không xác nhận toàn bộ dự đoán là đúng về ngữ nghĩa.

5.5. Phân tích kết quả và các phát hiện chính

Thứ nhất, cảm xúc tích cực chiếm ưu thế trong tập thực nghiệm. Có 30.118 bình luận được dự đoán tích cực, tương đương 86,24%. Đây là đặc điểm nổi bật của tập kết quả, nhưng chịu ảnh hưởng của cách lựa chọn, hợp nhất và lọc dữ liệu. Vì vậy, không thể sử dụng trực tiếp tỷ lệ này để kết luận mức độ chấp nhận nhạc AI của toàn bộ khán giả Việt Nam.

Thứ hai, lượng thảo luận phân bố không đồng đều giữa các nhóm khía cạnh. Trong các nhóm ngoài Khác, Minh bạch và ghi công có quy mô lớn nhất với 4.184 bình luận. Phản hồi chung và Karaoke và tông giọng lần lượt có 3.959 và 3.285 bình luận. Những nhóm này cung cấp các hướng nội dung để tiếp tục đọc và phân tích bình luận, nhưng mức độ phù hợp của nhãn vẫn cần được xem xét ở cấp từng bình luận.

Thứ ba, thứ hạng theo tỷ lệ tiêu cực khác với thứ hạng theo số lượng tiêu cực. Lời bài hát và cảm xúc có tỷ lệ tiêu cực cao nhất trong các nhóm có tên cụ thể, đạt 14,83%, với 147 bình luận. Trong khi đó, Minh bạch và ghi công có tỷ lệ 7,93% nhưng chứa 332 bình luận tiêu cực. Sự khác biệt cho thấy cần trình bày cả hai chỉ tiêu để tránh đánh giá chỉ dựa vào phần trăm.

Thứ tư, tỷ lệ nhóm Khác còn lớn. Có 12.953 bình luận, tương đương 37,09%, chưa được diễn giải thành các nhóm cụ thể. Việc giữ nhóm này giúp phản ánh đầy đủ giới hạn phân loại và tránh ép các bình luận không rõ nội dung vào một nhãn không phù hợp. Đồng thời, đây là nhóm cần ưu tiên kiểm tra khi cải thiện bộ khía cạnh hoặc phương pháp diễn giải cụm.

Thứ năm, một số video có ảnh hưởng đáng kể đến cấu trúc dữ liệu. Top 10 video chiếm khoảng 23,9% bình luận huấn luyện. Vì thế, một số chủ đề hoặc cách diễn đạt có thể nổi bật do tập trung ở những video có nhiều thảo luận, thay vì xuất hiện phổ biến trên toàn bộ video.

Nhìn chung, sự kết hợp giữa phân cụm, nhãn khía cạnh và cảm xúc giúp chuyển tập bình luận thành các thống kê có thể tra cứu và trực quan hóa. Kết quả phù hợp để khám phá dữ liệu và xác định những nhóm cần đọc sâu hơn. Tuy nhiên, các nhãn vẫn mang tính hỗ trợ phân tích, chưa thay thế việc đánh giá ngữ cảnh hoặc kiểm chứng độc lập.

CHƯƠNG 6. KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN

6.1. Kết luận

Đề tài xây dựng quy trình thu thập, tiền xử lý và phân tích bình luận liên quan đến nhạc AI trên YouTube, kết hợp các thành phần Docker, Apache Airflow, Apache Spark, GSDMM và mô hình phân tích cảm xúc tiếng Việt được huấn luyện trước. Dữ liệu được tổ chức dưới dạng Parquet, kết quả phân tích được thiết kế để lưu trữ trong PostgreSQL và phục vụ trực quan hóa qua BigQuery, Looker Studio.

Trong phần thực nghiệm, tập đầu vào đã chuẩn hóa gồm 73.247 bình luận được lọc còn 40.701 bình luận. Sau các bước chuẩn bị cho GSDMM, tập phân tích cuối cùng gồm 34.923 bình luận thuộc 1.468 video. Mô hình tạo ra 20 cụm, được diễn giải thành 11 nhóm có tên cụ thể và nhóm Khác. Mỗi bình luận được gán một khía cạnh chính và một nhãn cảm xúc chung.

Kết quả cảm xúc gồm 86,24% tích cực, 4,38% trung lập và 9,38% tiêu cực. Khi kết hợp với khía cạnh, hệ thống hỗ trợ so sánh quy mô thảo luận và phân bố cảm xúc giữa các nhóm. Những kết quả này cung cấp cơ sở xây dựng dashboard tổng quan, phân tích khía cạnh – cảm xúc và tra cứu bình luận chi tiết.

Đề tài đồng thời ghi nhận các giới hạn: nhóm Khác còn chiếm tỷ lệ lớn, nhãn khía cạnh được kế thừa từ cụm có thể chưa phù hợp với từng bình luận, và cảm xúc chung chưa phản ánh riêng cảm xúc hướng đến từng khía cạnh. Do chưa có đánh giá bằng tập nhãn chuẩn độc lập, các kết quả được xem là phân tích khám phá trên tập thực nghiệm, chưa phải kết luận đại diện cho toàn bộ phản ứng của khán giả Việt Nam đối với nhạc AI.

6.2. Hạn chế của đề tài

Một giới hạn xuyên suốt là thành phần của tập thực nghiệm: dữ liệu kiểm thử có phần giả lập, nên kết quả chủ yếu minh họa quy trình và khả năng tổng hợp. Để đưa ra kết luận về phản ứng thực tế của khán giả, cần thực nghiệm riêng trên tập thu thập thực tế có nguồn gốc được kiểm soát.

Thứ nhất, việc lựa chọn video còn phụ thuộc vào các tín hiệu gián tiếp. Hệ thống nhận diện video có khả năng liên quan đến nhạc AI chủ yếu thông qua từ khóa, tiêu đề, mô tả, thẻ và thông tin khai báo có thể truy xuất. Những tín hiệu này chưa xác minh trực tiếp quá trình sản xuất hoặc nội dung âm thanh. Vì vậy, tập dữ liệu vẫn có thể chứa video hướng dẫn, thảo luận về AI hoặc nội dung âm nhạc chưa phù hợp hoàn toàn với phạm vi nghiên cứu.

Thứ hai, tập bình luận chưa bảo đảm tính đại diện cho toàn bộ khán giả. Kết quả phụ thuộc vào từ khóa tìm kiếm, thời gian thu thập, khả năng truy xuất và hạn mức API. Đề tài tập trung vào bình luận tiếng Việt và sử dụng bình luận cấp cao nhất sau khi loại phản hồi. Ngôn ngữ bình luận không xác định được quốc tịch hoặc vị trí thực tế của người viết; người có bình luận cũng không đại diện cho toàn bộ người xem video.

Thứ ba, quá trình tiền xử lý sử dụng các quy tắc mang tính kinh nghiệm. Các bộ lọc ngôn ngữ, độ dài, nội dung toán và dấu hiệu lạc đề giúp giảm nhiễu nhưng có thể loại nhầm bình luận phù hợp hoặc giữ lại nội dung không liên quan. Việc khử trùng văn bản cũng làm thay đổi phân bố dữ liệu so với tập bình luận ban đầu. Do đó, tỷ lệ cảm xúc trong tập sau xử lý cần được hiểu trong phạm vi các bản ghi còn lại.

Thứ tư, việc gán khía cạnh phụ thuộc vào chất lượng phân cụm và cách diễn giải cụm. GSDMM tạo ra các nhóm văn bản dựa trên phân bố từ, không trực tiếp dự đoán tên khía cạnh. Mọi bình luận trong một cụm kế thừa cùng một nhãn, nên những cụm có nội dung lẫn nhau có thể dẫn đến gán sai khía cạnh. Trong tập kết quả hiện tại, nhóm "Khác" có 12.953 bình luận, chiếm khoảng 37,09%, cho thấy còn nhiều nội dung chưa được diễn giải thành các khía cạnh cụ thể hoặc chưa phù hợp với bộ nhãn.

Thứ năm, mỗi bình luận chỉ được gán một khía cạnh chính. Cách biểu diễn này đơn giản hóa quá trình tổng hợp nhưng chưa phản ánh đầy đủ những bình luận chứa nhiều ý. Đồng thời, sentiment được dự đoán cho toàn bộ bình luận, chưa phải cảm xúc riêng hướng đến khía cạnh được gán hoặc thái độ trực tiếp đối với AI.

Thứ sáu, chất lượng mô hình cảm xúc chưa được đánh giá độc lập đầy đủ trên dữ liệu của đề tài. Mô hình được sử dụng là mô hình có sẵn, chưa được tinh chỉnh riêng cho bình luận về nhạc AI. Những trường hợp mỉa mai, tiếng lóng, câu nhiều ý trái chiều và văn bản dài có thể bị dự đoán sai. Điểm softmax không phải độ chính xác đã được kiểm chứng; tỷ lệ nhãn tích cực cao cũng chưa chứng minh mô hình hoạt động tốt trên mọi lớp cảm xúc.

Ngoài ra, việc vận hành và mở rộng hệ thống còn phụ thuộc vào tài nguyên máy chạy, kết nối mạng, quota API và sự ổn định của các dịch vụ bên ngoài. Quy trình cập nhật mô hình, kiểm thử toàn bộ luồng và giám sát chất lượng dữ liệu cần tiếp tục được hoàn thiện. Việc tải kết quả lên BigQuery theo phương án hiện tại vẫn có thao tác thủ công.

6.3. Hướng phát triển

Trước hết, đề tài cần tiếp tục nâng cao chất lượng lựa chọn video và bình luận. Có thể xây dựng tập video được kiểm tra thủ công để đánh giá bộ lọc liên quan đến nhạc AI, phân biệt rõ sản phẩm âm nhạc, AI cover và nội dung hướng dẫn hoặc thảo luận. Đối

với bình luận, cần lưu lại lý do bị loại và kiểm tra mẫu định kỳ để điều chỉnh các quy tắc tiền xử lý.

Hướng phát triển tiếp theo là xây dựng tập dữ liệu đánh giá độc lập. Các bình luận được lựa chọn nên có sự phân bố theo khía cạnh, sentiment và độ dài, đồng thời được gán nhãn bởi người đánh giá theo hướng dẫn thống nhất. Kết quả có thể được sử dụng để đo mức độ đồng thuận, đánh giá chất lượng gán khía cạnh và tính các chỉ số Precision, Recall, Macro-F1 cùng ma trận nhầm lẫn cho mô hình cảm xúc.

Đối với GSDMM, hệ thống đã hỗ trợ lưu phiên bản, khóa gói mô hình, kiểm tra tính toàn vẹn và suy luận bằng mô hình cố định. Hướng phát triển tiếp theo là theo dõi tỷ lệ bình luận thiếu từ thuộc từ điển, đánh giá sự thay đổi dữ liệu và xác định thời điểm huấn luyện lại. Mỗi phiên bản mới cần được diễn giải cụm, kiểm tra bản tham chiếu và bảng ánh xạ trước khi sử dụng.

Đối với sentiment, có thể nghiên cứu tinh chỉnh mô hình bằng dữ liệu được gán nhãn trong lĩnh vực nhạc AI, đồng thời khảo sát ảnh hưởng của độ dài đầu vào và những cách diễn đạt đặc thù. Trong giai đoạn phát triển sâu hơn, có thể xem xét mô hình xác định cảm xúc hướng đến khía cạnh để giảm hạn chế của việc sử dụng cảm xúc chung cho toàn bộ câu.

Về hệ thống, cần tăng cường kiểm thử toàn bộ luồng Docker–Airflow, kiểm tra dữ liệu đầu vào–đầu ra và theo dõi các lần xử lý thất bại. Cơ chế lưu kết quả theo phiên bản, chạy lại an toàn và tận dụng kết quả đã tính cho các bình luận không thay đổi có thể giúp giảm thời gian xử lý. Khi có nhu cầu, bước chuyển dữ liệu từ PostgreSQL sang BigQuery cũng có thể được tự động hóa sau khi đã thiết lập cơ chế xác thực và kiểm tra tính nhất quán.

Về trực quan hóa, dashboard có thể được mở rộng bằng cách liên kết kết quả bình luận với siêu dữ liệu video và snapshot tương tác đã được thu thập. Việc bổ sung thông tin cần đi kèm kiểm tra chất lượng và khóa liên kết để tránh sai lệch số lượng bình luận. Đồng thời, dashboard nên thể hiện rõ phạm vi dữ liệu, các trường hợp “Khác” và giới hạn của nhãn dự đoán, giúp người sử dụng diễn giải kết quả phù hợp.

TÀI LIỆU THAM KHẢO

[1] Copet, J. và cộng sự (2023). Simple and Controllable Music Generation. Advances in Neural Information Processing Systems.

https://arxiv.org/abs/2306.05284

[2] Google. YouTube Data API v3 — Overview.

https://developers.google.com/youtube/v3/getting-started

[3] Liu, B. (2012). Sentiment Analysis and Opinion Mining. Morgan & Claypool Publishers.

https://doi.org/10.2200/S00416ED1V01Y201204HLT016

[4] Pontiki, M. và cộng sự (2014). SemEval-2014 Task 4: Aspect Based Sentiment Analysis. Proceedings of the 8th International Workshop on Semantic Evaluation, 27–35.

https://aclanthology.org/S14-2004/

[5] Yin, J. và Wang, J. (2014). A Dirichlet Multinomial Mixture Model-based Approach for Short Text Clustering. Proceedings of the 20th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining.

https://doi.org/10.1145/2623330.2623715

[6] Devlin, J., Chang, M.-W., Lee, K. và Toutanova, K. (2019). BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding. Proceedings of NAACL-HLT, 4171–4186.

https://aclanthology.org/N19-1423/

[7] Nguyen, D. Q. và Nguyen, A. T. (2020). PhoBERT: Pre-trained language models for Vietnamese. Findings of EMNLP, 1037–1042.

https://aclanthology.org/2020.findings-emnlp.92/

[8] Nguyen, N., Phan, T., Nguyen, D.-V. và Nguyen, K. (2023). ViSoBERT: A Pre-Trained Language Model for Vietnamese Social Media Text Processing. Proceedings of EMNLP, 5191–5207.

https://aclanthology.org/2023.emnlp-main.315/

[9] 5CD-AI. Vietnamese-Sentiment-visobert — Model repository. Hugging Face.

https://huggingface.co/5CD-AI/Vietnamese-Sentiment-visobert

[10] Mã nguồn dự án Big-Data-YTB. Nhánh main, commit 8a97a77 — Update final. Thời điểm đối chiếu: 24/10/2026.

https://github.com/akhoaaaa27/Big-Data-YTB/tree/8a97a77ce44827e98ff468c738200228c8d0059b

PHỤ LỤC A. BỘ NHÃN KHÍA CẠNH VÀ CẢM XÚC

A.1. Bộ nhãn khía cạnh

Các nhãn dưới đây là tên diễn giải ở cấp cụm, không phải bộ quy tắc từ khóa dự đoán độc lập cho từng bình luận. Một bình luận kế thừa đúng một nhãn từ cụm của mình; nhiều cụm có thể cùng ánh xạ vào một nhãn.

Nhãn khía cạnh	Ý nghĩa diễn giải
Giai điệu	Nhận xét về tuyến giai điệu, độ bắt tai và cách phát triển giai điệu.
Phối khí và nhạc cụ	Nhận xét về bản phối, hòa âm, nhạc cụ và các lớp âm nhạc.
Chất lượng âm thanh	Nhận xét về độ rõ, âm lượng, cân bằng âm và lỗi kỹ thuật âm thanh.
Lời bài hát và cảm xúc	Nội dung lời, thông điệp và cảm xúc gợi lên khi nghe.
Trải nghiệm nghe	Cảm nhận tổng thể, mức độ dễ nghe và trải nghiệm thưởng thức.
Sáng tạo và phong cách	Tính mới lạ, dấu ấn, cách thể hiện và phong cách sản phẩm.
Quy trình và chỉnh sửa	Công cụ, prompt, thao tác tạo nhạc và chỉnh sửa sản phẩm.
Nhịp điệu và cấu trúc	Nhịp, tiết tấu, chuyển đoạn và cách tổ chức bài hát.
Minh bạch và ghi công	Nguồn gốc, công bố sử dụng AI và ghi nhận đóng góp liên quan.
Karaoke và tông giọng	Bản karaoke, instrumental, tông và khả năng hát theo.
Phản hồi chung	Các phản hồi tổng quát chưa tập trung vào một đặc điểm kỹ thuật.
Khác	Cụm chưa rõ nội dung, ngoài phạm vi hoặc trường hợp chưa đủ căn cứ gán cụm.

A.2. Bộ nhãn cảm xúc

Nhãn trong kết quả	Nhãn mô hình	Ý nghĩa
Tích cực	positive / POS	Sắc thái tích cực của toàn bộ bình luận.
Trung lập	neutral / NEU	Sắc thái trung lập hoặc chưa thể hiện đánh giá rõ ràng theo dự đoán mô hình.
Tiêu cực	negative / NEG	Sắc thái tiêu cực của toàn bộ bình luận.

Hệ thống không có nhãn mixed. Nhóm Khác vẫn được dự đoán cảm xúc và được giữ trong thống kê mặc định. Trung lập không đồng nghĩa với không liên quan; một câu

hỏi hoặc yêu cầu cũng không tự động nhận nhãn Trung lập nếu mô hình dự đoán nhãn khác.

A.3. Nguyên tắc biểu diễn

Mỗi comment_id có một dòng kết quả, một cluster, một aspect và một sentiment. Với bình luận có nhiều ý như “Giọng hát hay nhưng âm thanh hơi rè”, hệ thống vẫn giữ một khía cạnh chính theo cụm và một cảm xúc chung; không tách thành hai bản ghi khía cạnh–cảm xúc. Nhãn này cần được đối chiếu ngữ cảnh khi sử dụng làm ví dụ phân tích.

A.4. Quản lý bảng tên cụm

Bảng cluster_aspects.json phải tương ứng với mô hình, bảng từ nổi bật và bản gán nhãn tham chiếu. Khi đổi tên khía cạnh, cần cập nhật bản tham chiếu rồi khóa lại manifest; không chỉ sửa JSON và tiếp tục dùng chữ ký cũ. Các kết quả đã xuất trước đó không tự đổi nhãn theo JSON mới.

PHỤ LỤC B. LƯỢC ĐỒ DỮ LIỆU VÀ CƠ SỞ DỮ LIỆU

B.1. Phân biệt lưu trữ Parquet và PostgreSQL

Các tập videos, comments và video_snapshots được lưu ở tầng staging/core dưới dạng Parquet. Chúng không mặc nhiên là ba bảng đã được tạo trong PostgreSQL. Module spark_mart.py nạp các trường phục vụ phân tích vào ba bảng Mart được mô tả dưới đây.

B.2. Bảng fact_comment_sentiment

Cột	Kiểu PostgreSQL	Vai trò/ràng buộc
comment_id	TEXT	Khóa chính
video_id	TEXT	Mã video; NOT NULL
cluster	INTEGER	Mã cụm; có thể -1 khi không đủ từ thuộc từ điển
aspect	TEXT	Một khía cạnh chính; NOT NULL
sentiment	TEXT	Cảm xúc chung; NOT NULL
sentiment_score	DOUBLE PRECISION	Điểm của nhãn được chọn
sentiment_negative	DOUBLE PRECISION	Điểm nhãn tiêu cực
sentiment_neutral	DOUBLE PRECISION	Điểm nhãn trung lập
sentiment_positive	DOUBLE PRECISION	Điểm nhãn tích cực
published	TIMESTAMPTZ	Ngày/thời gian đăng đã chuẩn hóa
likes	BIGINT	Lượt thích bình luận
text	TEXT	Nội dung bình luận
loaded_at	TIMESTAMPTZ	Thời điểm nạp; mặc định NOW(), NOT NULL

video_id là khóa liên kết logic với tập video. Schema SQL hiện hành chưa khai báo ràng buộc FOREIGN KEY tới một bảng videos trong PostgreSQL.

B.3. Các bảng tổng hợp

Bảng	Các cột	Khóa chính
agg_aspect_sentiment	aspect, sentiment, comment_count, total_for_aspect, percent_within_aspect, refreshed_at	aspect + sentiment

Bảng	Các cột	Khóa chính
agg_video_sentiment	video_id, sentiment, comment_count, total_for_video, percent_within_video, refreshed_at	video_id + sentiment

Hai bảng được dựng lại từ fact_comment_sentiment trong cùng giao dịch cập nhật. incoming_comment_sentiment là bảng tạm dùng khi nạp, không phải bảng phục vụ dashboard và được xóa khi commit.

B.4. Các tập dữ liệu Parquet

Tập dữ liệu	Nhóm trường chính
Staging videos	video_id, keyword, title, channel_id, channel_title, description, tags, published_at, thuộc tính nội dung, source, fetched_at
Staging comments	comment_id, video_id, thread_id, parent_id, is_reply, author_display_name, author_channel_id, text, like_count, published_at, updated_at, total_reply_count, source, fetched_at
Staging video_snapshots	video_id, snapshot_date, snapshot_at, view_count, like_count, comment_count
Silver comments_clean	comment_id, video_id, author, text, likes, published, tokens

Snapshot Core được khử trùng theo video_id và snapshot_date, giữ lần ghi nhận phù hợp trong ngày. Đây là quy tắc xử lý Parquet, không phải một ràng buộc khóa chính SQL đã được khai báo.

B.5. Lược đồ file kết quả thực nghiệm

File comments_sentiment.parquet cũ có 17 cột: comment_id, video_id, author, text, likes, published, tokens, text_clean, text_gsdmm, cluster, aspect, sentiment, sentiment_score, sentiment_negative, sentiment_neutral, sentiment_positive và sentiment_truncated.

PostgreSQL chỉ nhận các cột đã xác định trong schema Mart; các trường tác giả, tokens, text_clean, text_gsdmm và sentiment_truncated được giữ trong file Parquet/CSV khi cần truy vết hoặc kiểm tra. Do đó, số cột của file kết quả không đồng nhất với số cột bảng PostgreSQL.

B.6. Kết nối và cập nhật dữ liệu

Các container trong cùng mạng Compose kết nối PostgreSQL bằng postgres:5432. Ứng dụng chạy trên Windows kết nối 127.0.0.1:5433 theo cấu hình cổng hiện hành. Database kết quả là ytb_mart; database airflow phục vụ metadata điều phối.

pgAdmin có thể được bổ sung làm giao diện quản trị, nhưng không phải thành phần bắt buộc của mô hình phân tích. PostgreSQL không cung cấp trang web quản trị mặc định. Việc xuất dữ liệu và tải lên BigQuery vẫn được thực hiện thủ công; dashboard sử dụng lần cập nhật dữ liệu gần nhất.